Nasjonalbibliotekets data, språkmodeller og forskningsverktøy

for

HARK2020 – Digitale verktøy for utforskning av tekster

05.november 2026

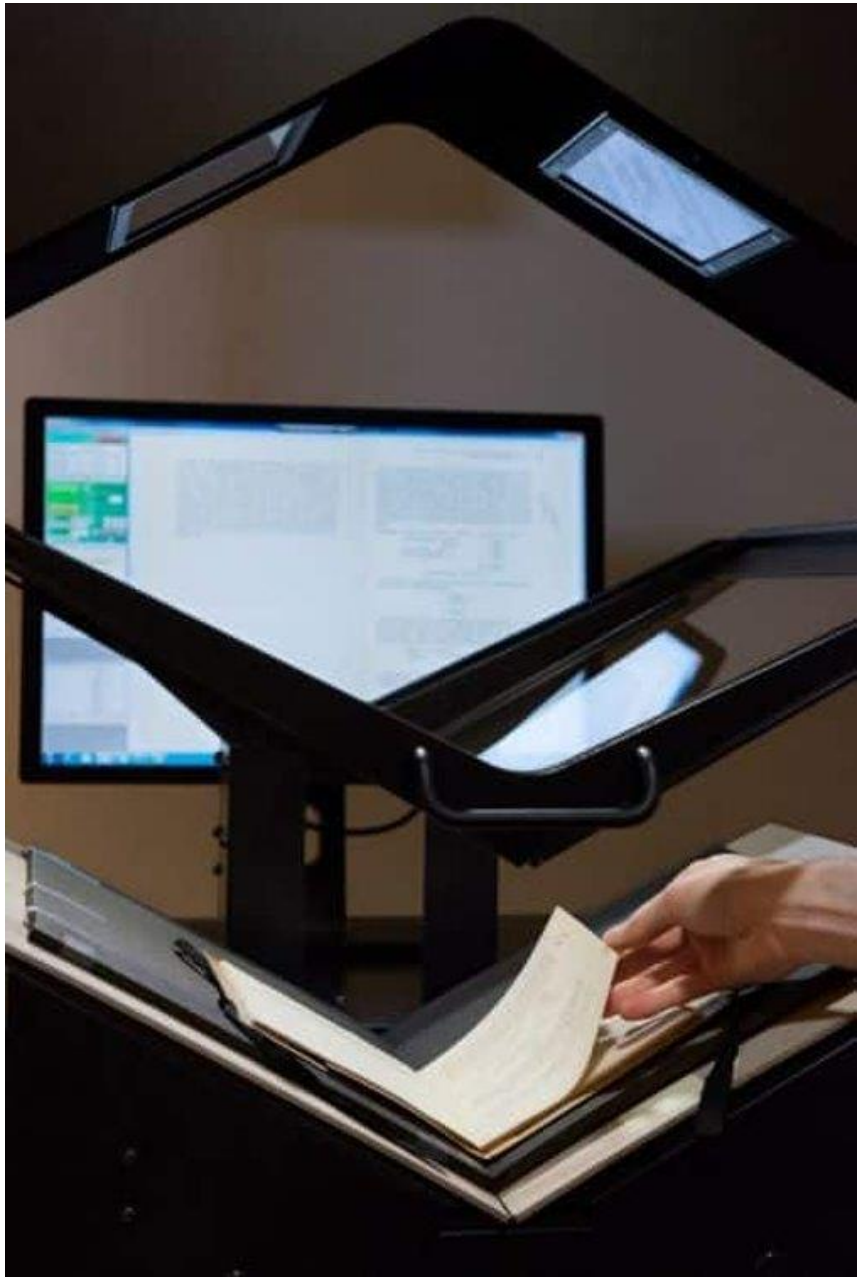
Plan for idag

- Introduksjon: om Nasjonalbiblioteket
  - Pliktavlevering og digitalisering
  - Nettbiblioteket
  - DH-lab: api og apper
  - Språkmodeller
- Brukseksempler
  - hvordan lage dokumentvektorer med dhlab
  - hvordan lage dokumentvektorer med borealis-embed
  - Temamodellering basert på dokumentvektorer

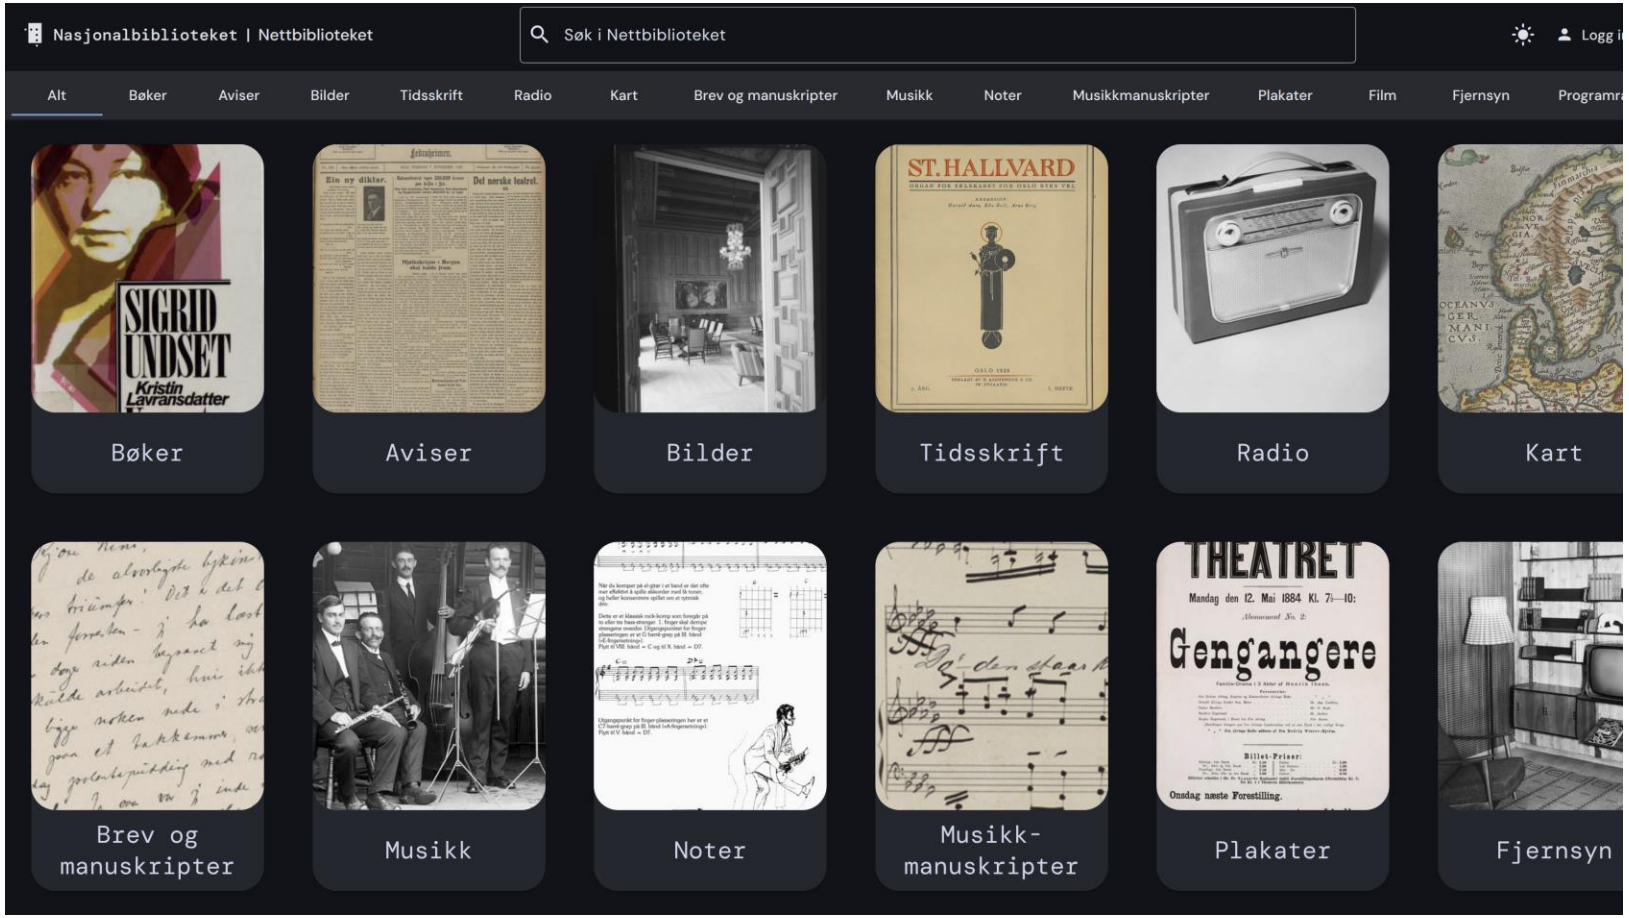
Gjerne rekk opp hånda og spør underveis!



Nasjonalbiblioteket samler inn og bevarer det meste som publiseres i Norge

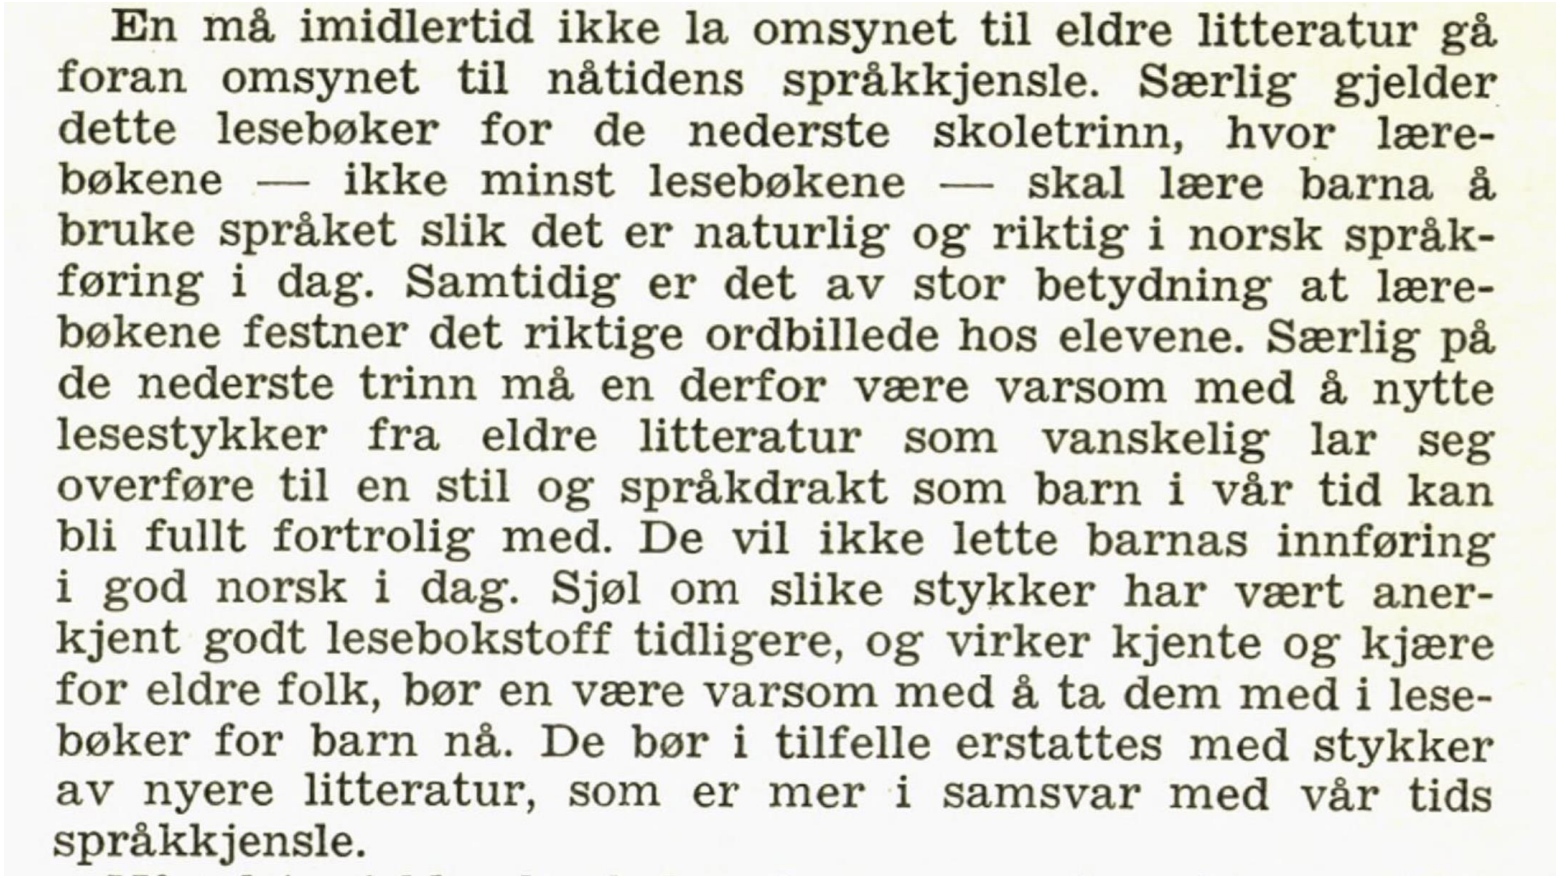


Siden 2006 har vi jobbet med å digitalisere samlinga



Den digitaliserte samlinga er tilgjengelig i nettbiblioteket på nb.no/search

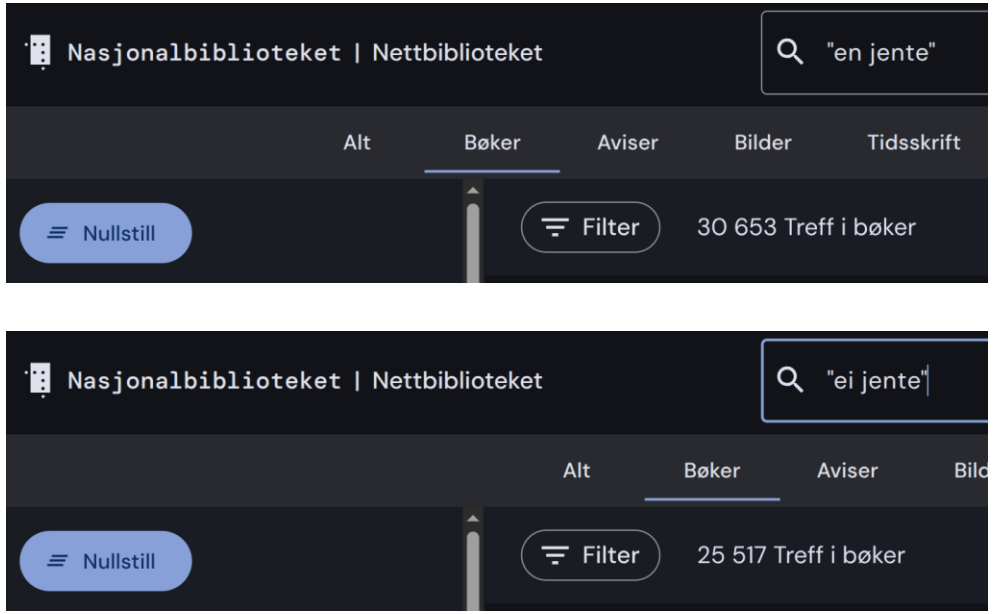
Nettbiblioteket er nyttig for nærlesing,

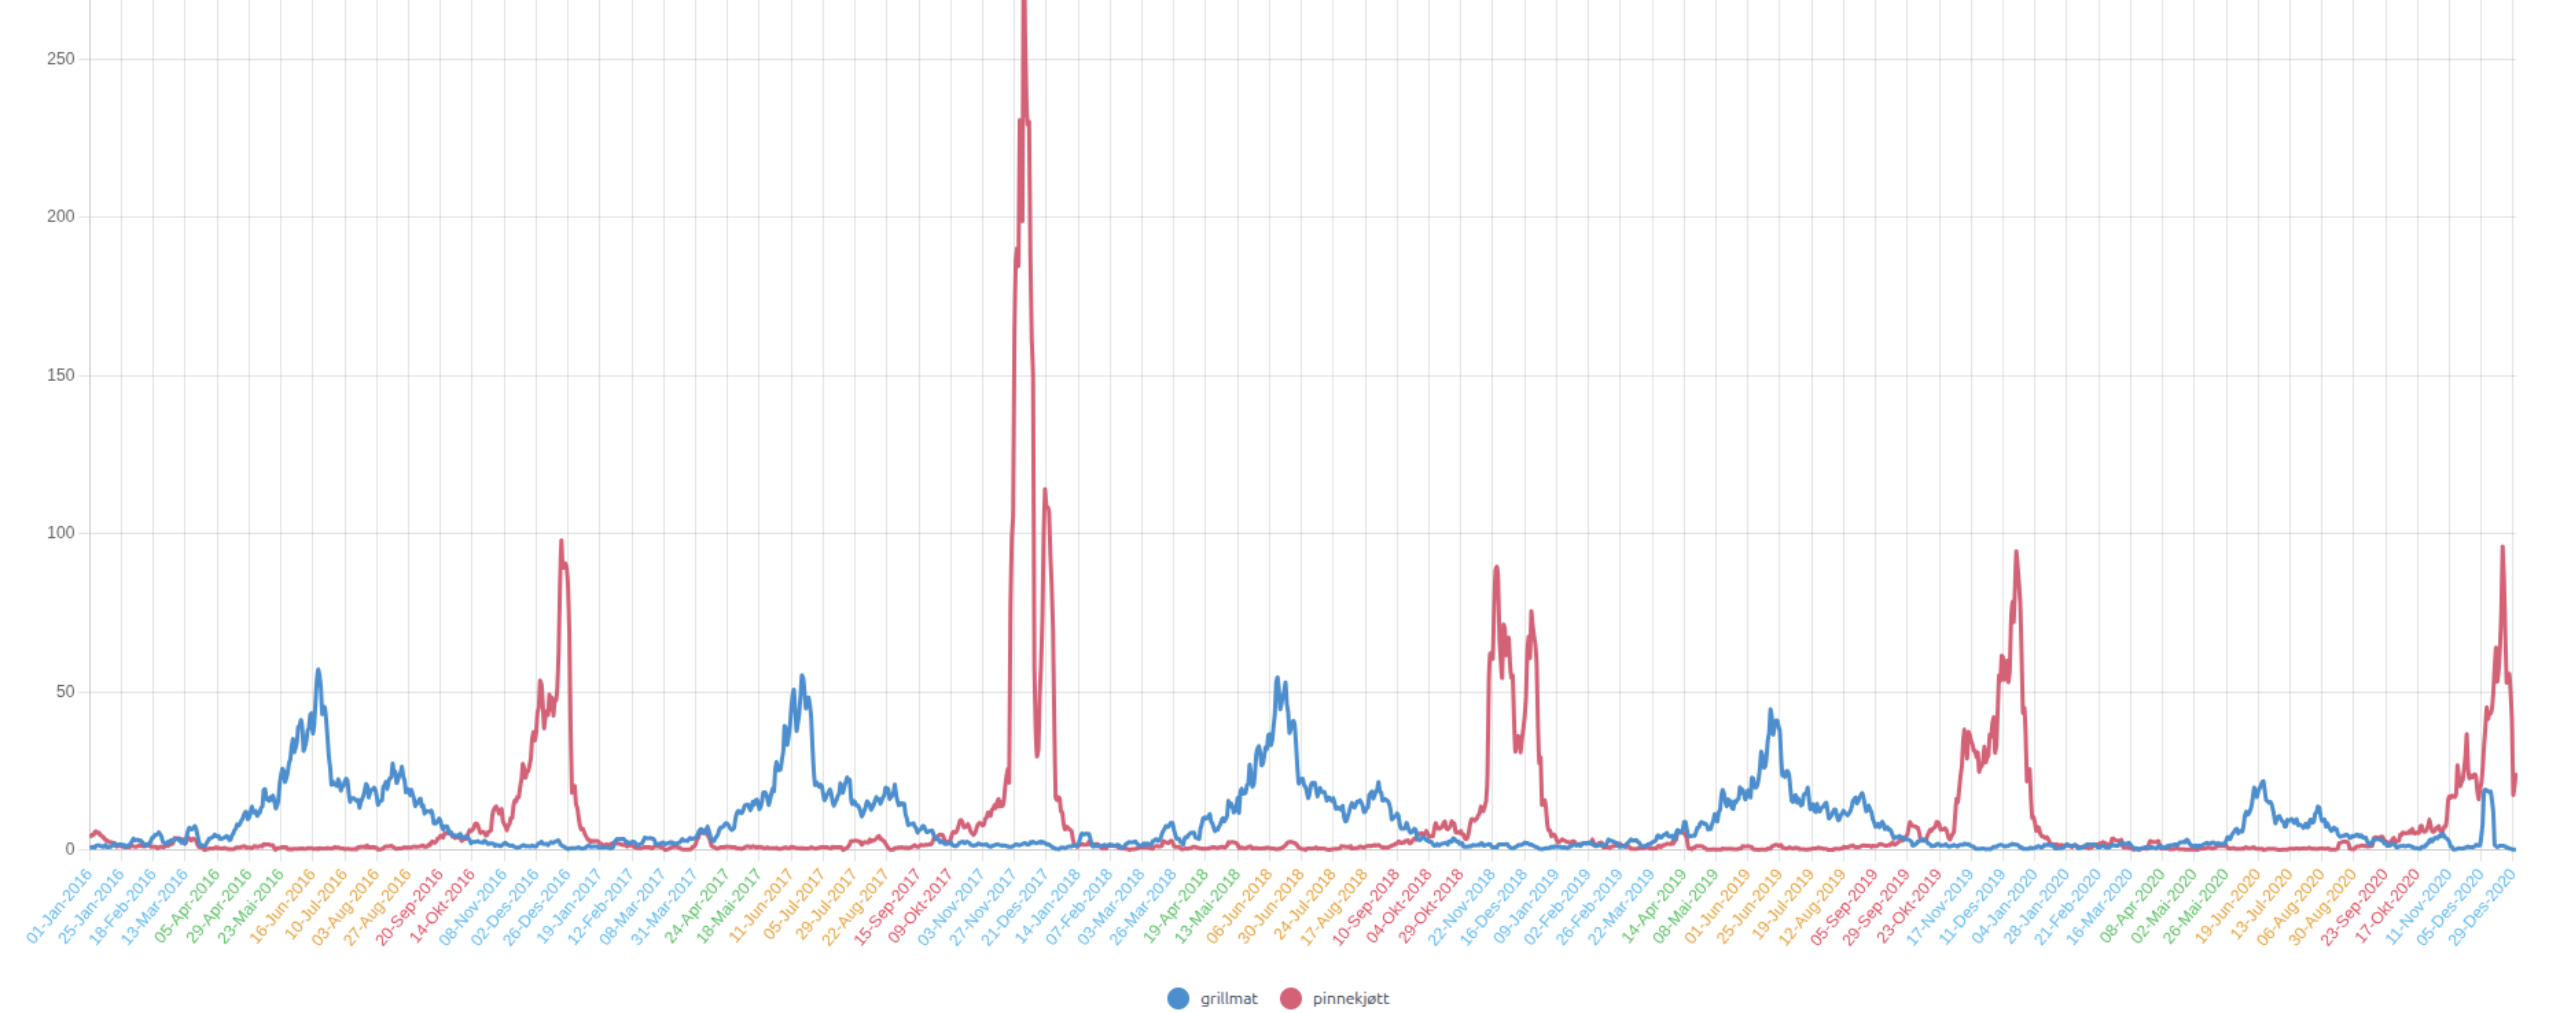


En må imidlertid ikke la omsynet til eldre litteratur gå foran omsynet til nåtidens språkkjensle. Særlig gjelder dette lesebøker for de nederste skoletrinn, hvor lærebøkene — ikke minst lesebøkene — skal lære barna å bruke språket slik det er naturlig og riktig i norsk språkføring i dag. Samtidig er det av stor betydning at lærebøkene festner det riktige ordbillede hos elevene. Særlig på de nederste trinn må en derfor være varsom med å nytte lesestykker fra eldre litteratur som vanskelig lar seg overføre til en stil og språkdrakt som barn i vår tid kan bli fullt fortrolig med. De vil ikke lette barnas innføring i god norsk i dag. Sjøl om slike stykker har vært anerkjent godt lesebokstoff tidligere, og virker kjente og kjære for eldre folk, bør en være varsom med å ta dem med i lesebøker for barn nå. De bør i tilfelle erstattes med stykker av nyere litteratur, som er mer i samsvar med vår tids språkkjensle.

https://www.nb.no/items/b4090846a103faaa0df6ad350de33051?page=16

og kan til en viss grad
brukes
til kvantitativ analyse,

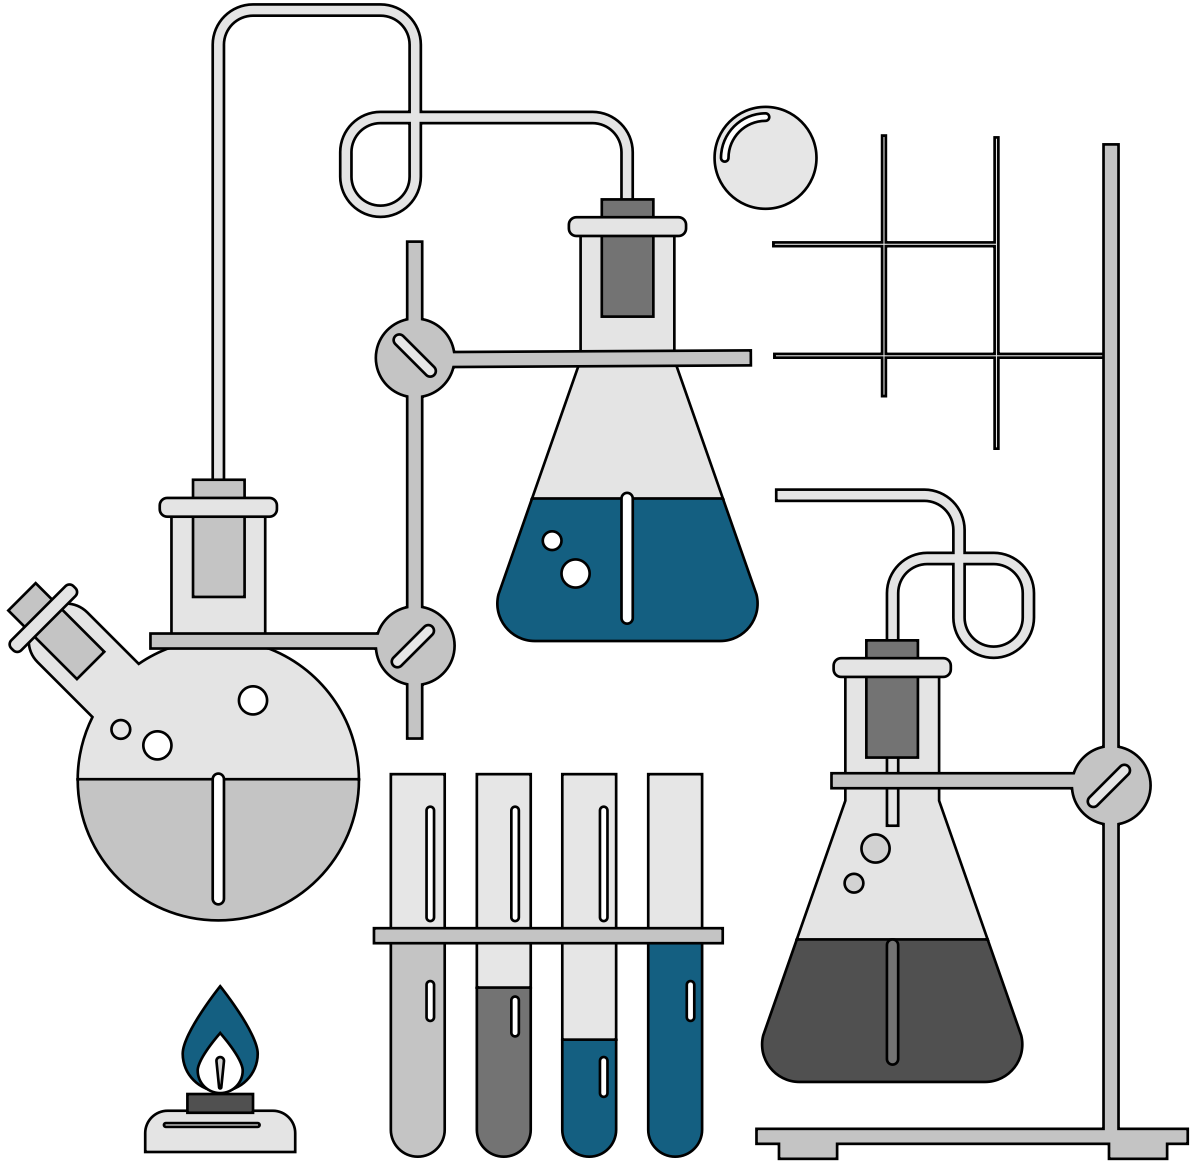




men for mer avanserte analyser
trengs andre verktøy

DH-lab er NBs laboratorium for digital humaniora

Vi utvikler verktøy og metoder for utforskning og analyse av NBs digitale samling



dhlab er også navnet på vårt api for digital tekstanalyse

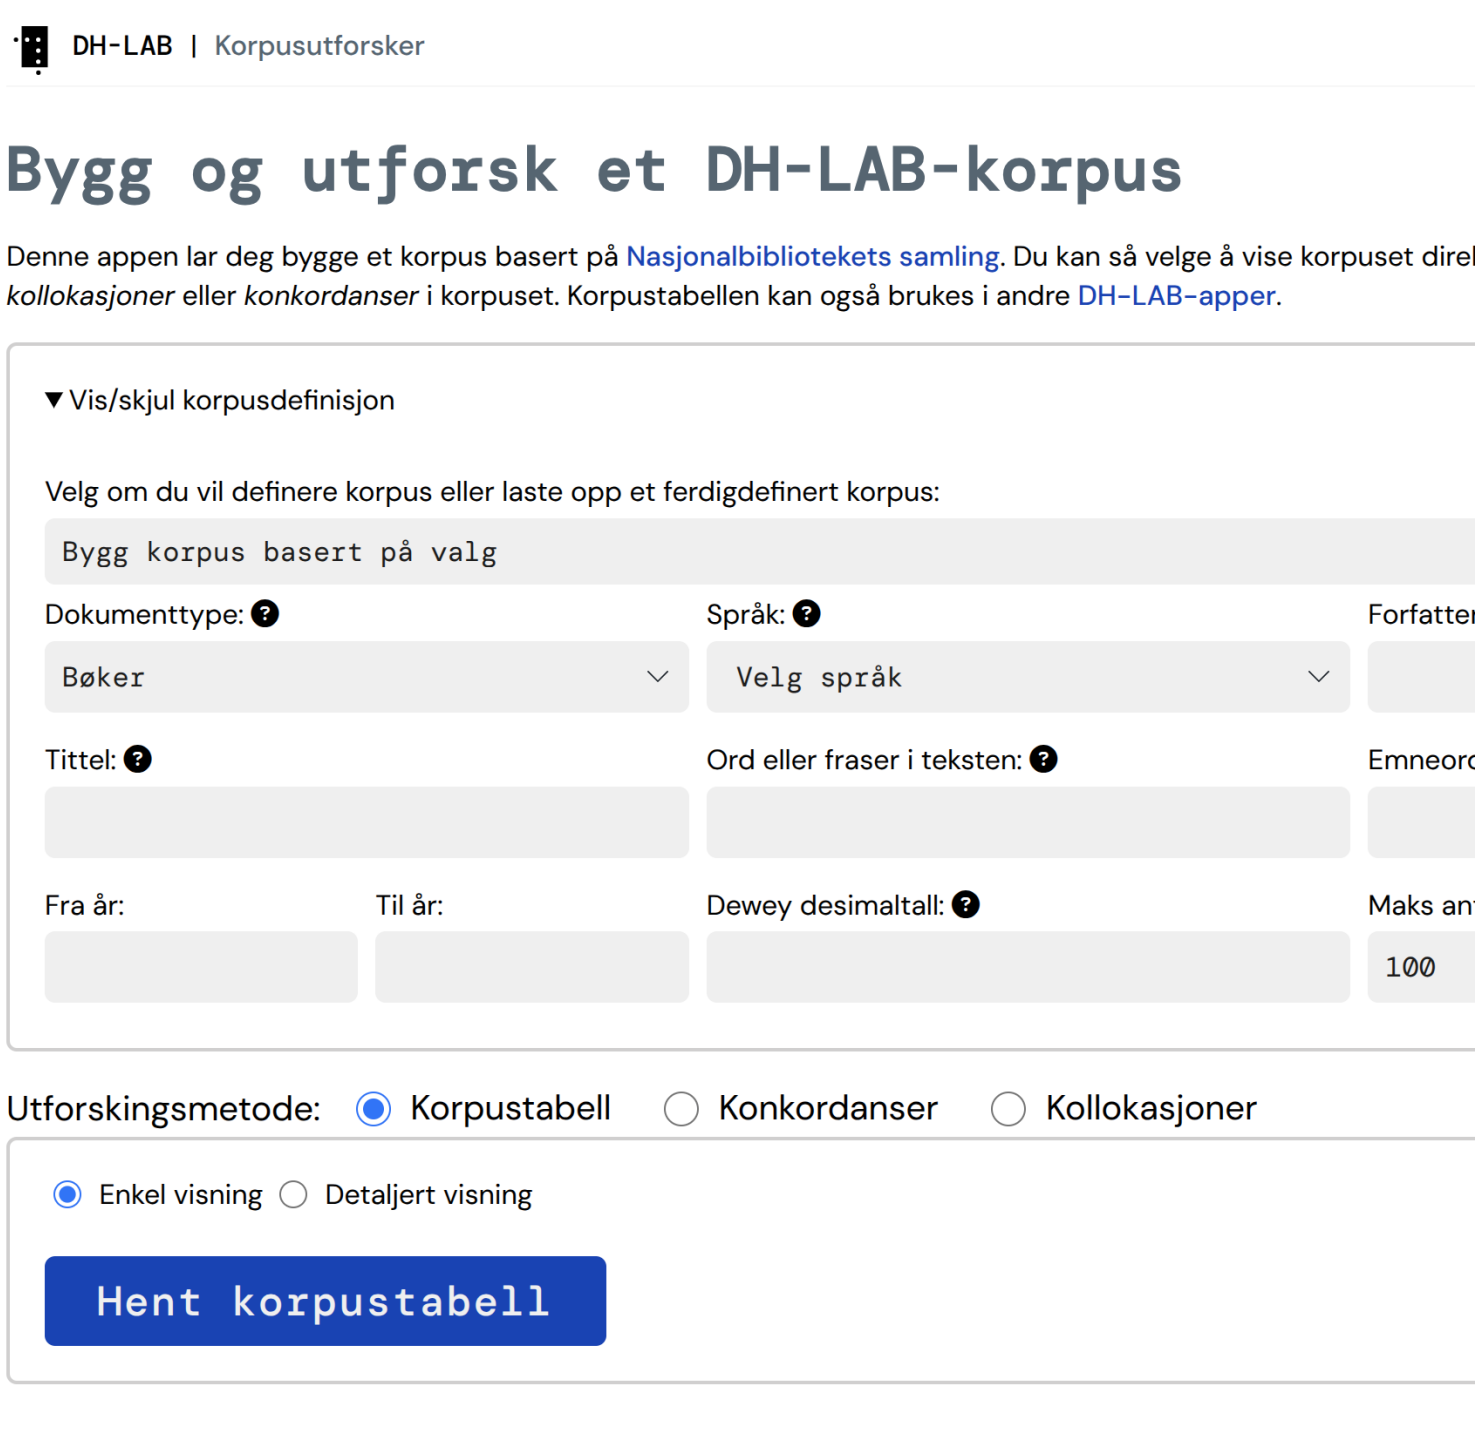
REST api: https://api.nb.no/dhlab/

Pythonpakke på PyPi:
https://pypi.org/project/dhlab/

Brukseksempler og tutorial pythonpakka:
https://nationallibraryofnorway.github.io/digital_tekstanalyse/index.html

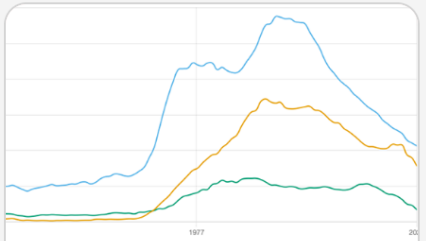


Vi har laget flere webapper basert på dhlab-apiet



Finn våre apper her:

nb.no/dh-lab/apper/



APP

NB N-gram

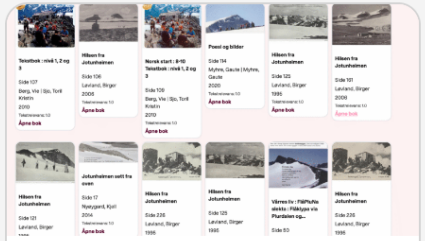
Finn og sammenlikn frekvensen av ord . Se og last ned trendlinjer, samt grunnlagsdata for grafen.



APP

Korpus

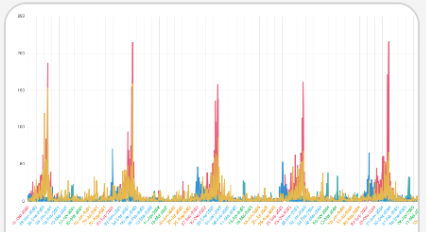
Bygg ditt eget korpus med tekster fra NBs samling, basert på nøkkelord og metadata. Definisjonen kan lastes ned og gjenbrukes i andre apper. Appen lar deg også undersøke ord i kontekst (konkordans) og samforekomst av ord (kollokasjon).



APP

Bildesøk

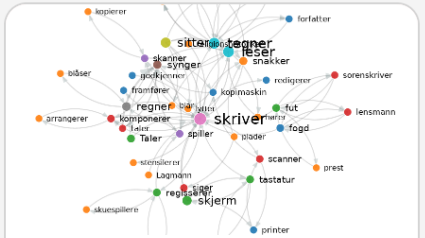
Søk etter bilder i Nasjonalbibliotekets boksamling, enten med tekst og opplastet bilde.



APP

Dagsplott

Dagsplott gjør det mulig å vise trender à la NB N-gram, men med høyere oppløsning. Følg utviklingen for ett eller flere ord dag for dag.



APP

Galakser

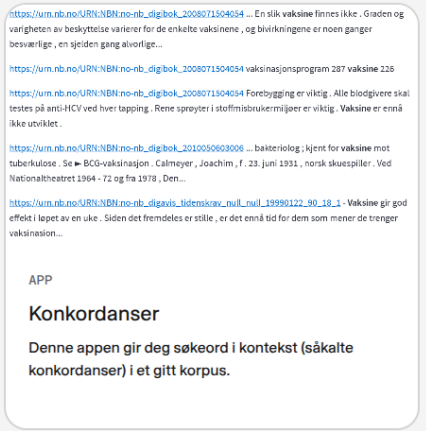
Galaksene er en slags ordsky som viser ord i relasjon til andre ord. Ordene opptrer i en grafstruktur bygd opp fra ord som forekommer sammen i en koordinasjon, som for eksempel bil og båt.



APP

Bildesøk

Søk etter i bilder i Nasjonalbibliotekets bøker.



https://urn.nb.no/URN:NBN:no-nb_digibok_2008071504054 ... En slik **vaksine** finnes ikke . Graden og varigheten av beskyttelse varierer for de enkelte vaksinene , og bivirkningene er noen ganger besværlige , en sjelden gang alvorlige...

https://urn.nb.no/URN:NBN:no-nb_digibok_2008071504054 vaksinasjonsprogram 287 **vaksine** 226

https://urn.nb.no/URN:NBN:no-nb_digibok_2008071504054 Forebygging er viktig . Alle blodgivere skal testes på anti-HCV ved hver tapping . Rene sprøyter i stoffmisbrukermiljøer er viktig . **Vaksine** er ennå ikke utviklet .

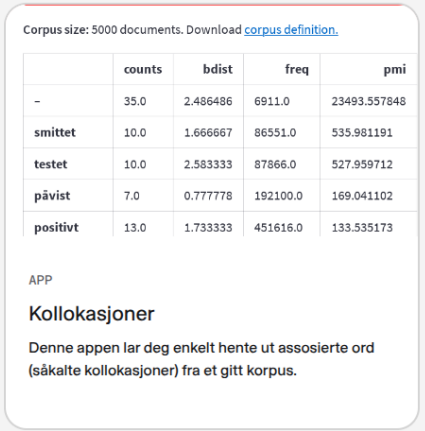
https://urn.nb.no/URN:NBN:no-nb_digibok_2010050603006 ... bakteriolog ; kjent for **vaksine** mot tuberkulose . Se ► BCG-vaksinasjon . Calmeyer , Joachim , f . 23. juni 1931 , norsk skuespiller . Ved Nationaltheatret 1964 - 72 og fra 1978 , Den...

https://urn.nb.no/URN:NBN:no-nb_digavis_tidsskrav_null_null_19990122_90_18_1 - **Vaksine** gir god effekt i løpet av en uke . Siden det fremdeles er stille , er det ennå tid for dem som mener de trenger vaksinasjon...

APP

Konkordanser

Denne appen gir deg søkeord i kontekst (såkalte konkordanser) i et gitt korpus.



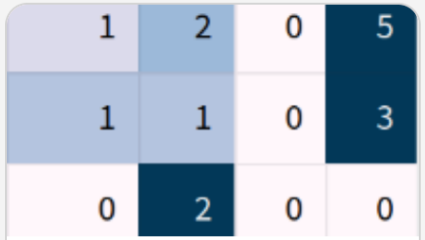
Corpus size: 5000 documents. Download corpus definition.

	counts	bdist	freq	pmi
–	35.0	2.486486	6911.0	23493.557848
smittet	10.0	1.666667	86551.0	535.981191
testet	10.0	2.583333	87866.0	527.959712
påvist	7.0	0.777778	192100.0	169.041102
positivt	13.0	1.733333	451616.0	133.535173

APP

Kollokasjoner

Denne appen lar deg enkelt hente ut assosierte ord (såkalte kollokasjoner) fra et gitt korpus.



1	2	0	5
1	1	0	3
0	2	0	0

APP

Ordfrekvenser

Appen gir deg informasjon om frekvenser av ord for et gitt korpus. Resultatet er en såkalt dokument-term-matrise som kan brukes i statistisk analyse.

Bibliografi over prosjekter som har brukt DH-lab

Sælthun, Sigurd and Sandring, Vetle Lars Wisløff (2026) “Shifting Narratives of the Alta controversy: Innovations in Memory Studies Using Natural Language Processing”, *Memory Studies*, 17506980251409270. Tilgjengelig fra: https://doi.org/10.1177/17506980251409270 (Hentet: 2026-03-03)

Tønnessen, Jon Carlstedt and Birkenes, Magnus Breder (2025) “Providing Web Archive News Articles as Corpus Data”, *Journal of Open Humanities Data*, 11(2), 1-12. Tilgjengelig fra: http://openhumanitiesdata.metajnl.com/articles/10.5334/johd.281/ (Hentet: 2025)

Sverdljuk, Jana (2025) “Representations of Indigenous peoples and the construction of Norwegian identity in America: A corpus-based study” in Hemstad, Ruth and Rasmussen, Terje (ed.) *Nordic Transatlantic Crossings*. London: Routledge, 81-97.

Skogmo, Siri Fürst et al. (2025) “Oversatt litteratur på kartet: Digitale metoder og tverrfaglig samarbeid i bibliografisk oversettelsesforskning”, *Nordisk tidsskrift for oversettelses- og tolkeforskning*, 1(2), 51-70.

Opach, Tomasz et al. (2025) “Digital Literary Mapping: Exploring User Needs and Pedagogical Potentials in Literary Geographies with the ImagiNation Map Tool”, *Cartography and Geographic Information Science*, 1-18. Tilgjengelig fra: https://doi.org/10.1080/15230406.2025.2588459

Roald, Marie, Birkenes, Magnus Breder, og Johnsen, Lars G. Bagøien (2024) “Visual Navigation of Digital Libraries: Retrieval and Classification of Images in the National Library of Norway’s Digitised Book Collection”, *arXiv preprint*,

Malvik, Anders Skare et al. (2024) “ImagiNation-korpuset”, *Edda*, 111(3), 120-137. Tilgjengelig fra: https://doi.org/10.18261/edda.111.3.3 (Hentet: 2025-11-10)

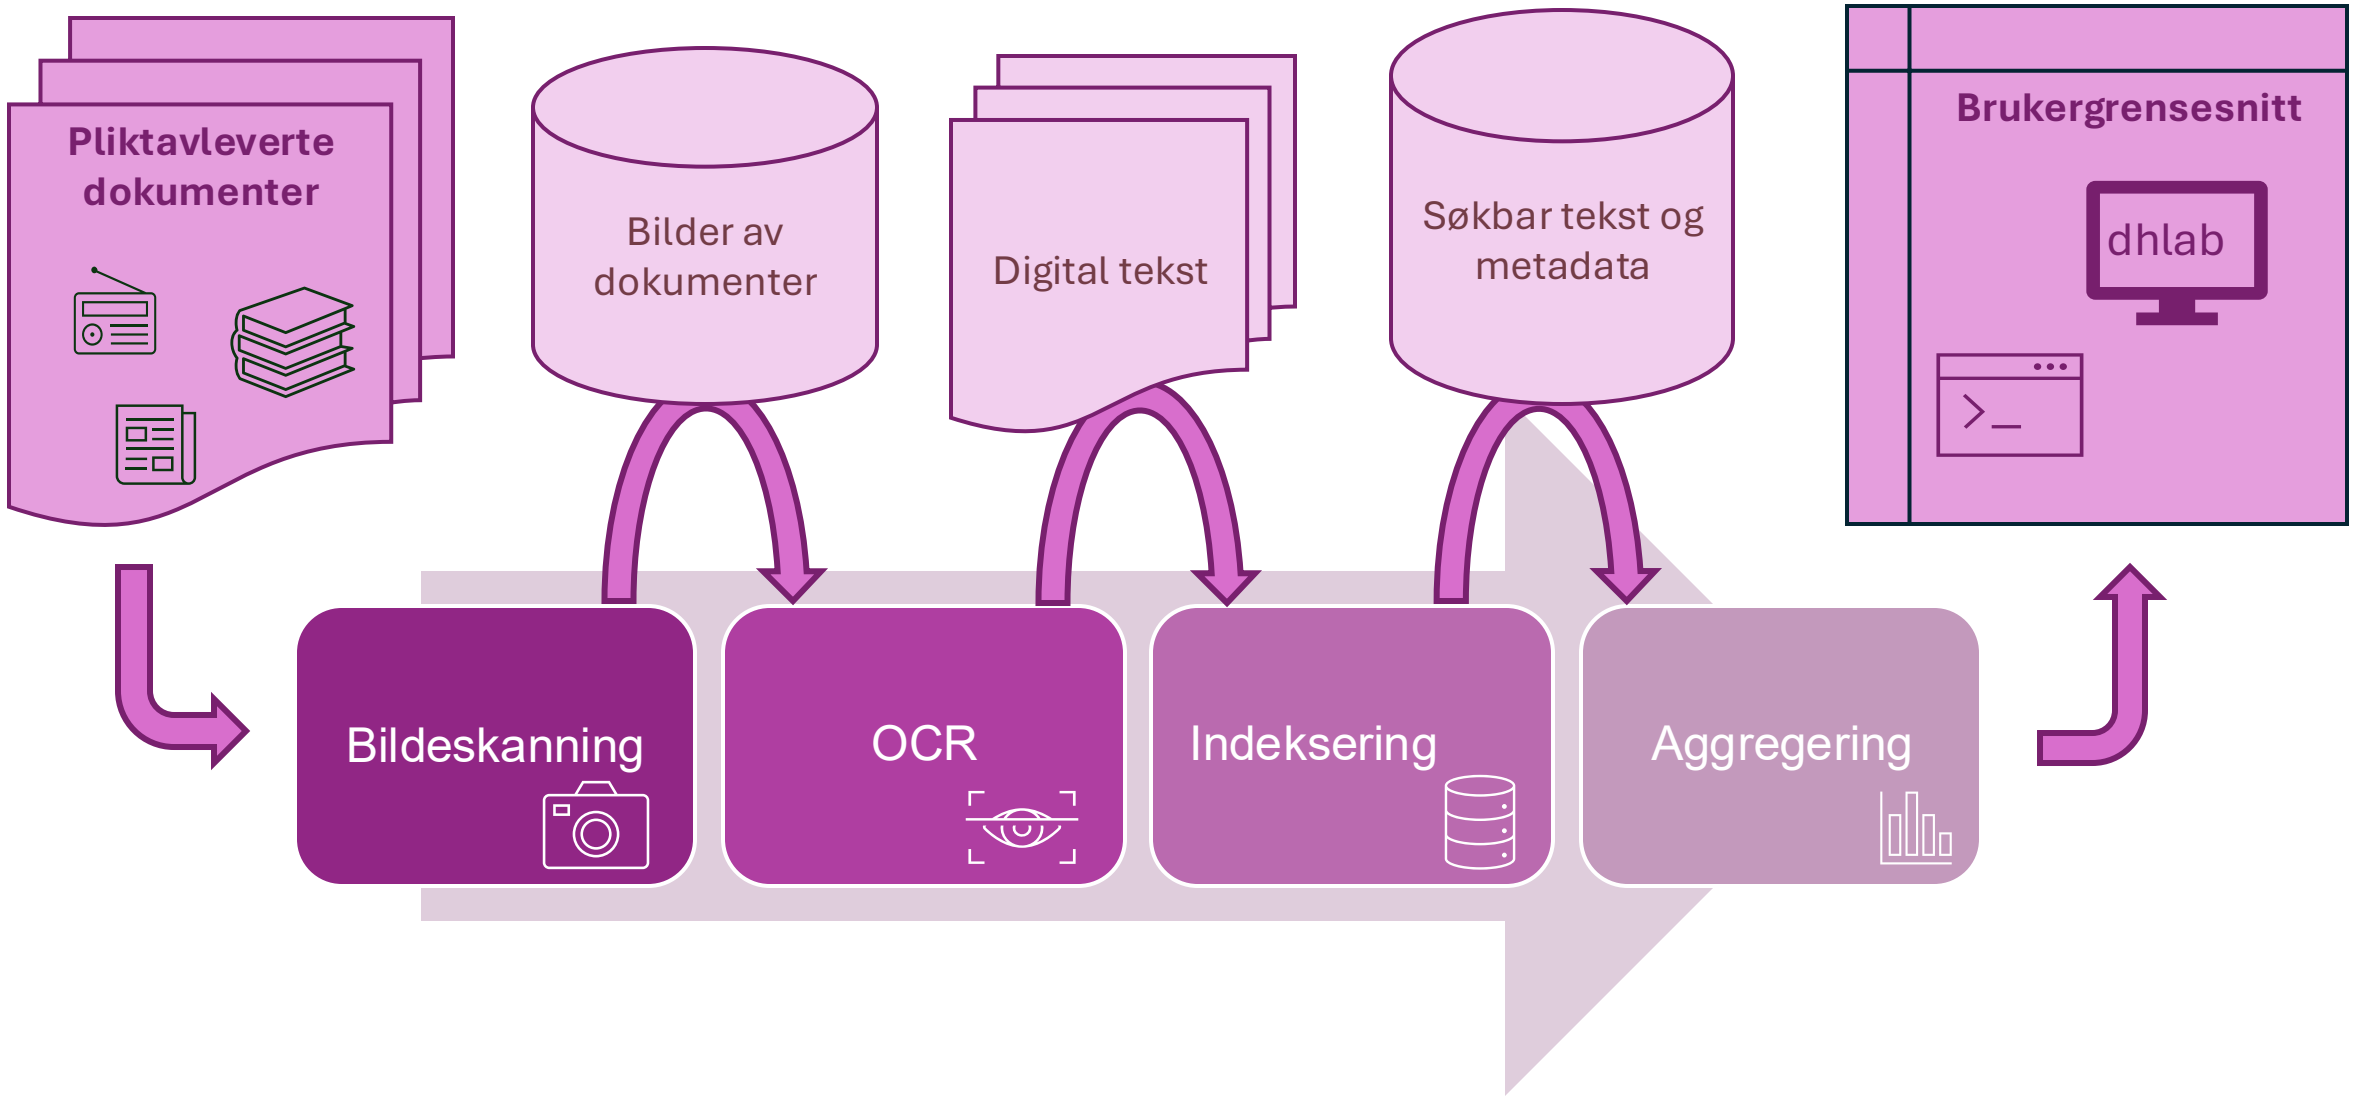
Kvinnsland, Ranveig, Dale, Ingerid Løyning, og Tungland, Lars Magne (2024) “Rediscovering the 1890s: A Norwegian Poetry Corpus”, *Proceedings of the Computational Humanities Research Conference 2024*, 1259-1271. Tilgjengelig fra: https://ceur-ws.org/Vol-3834/#paper24 (Hentet: 2024)

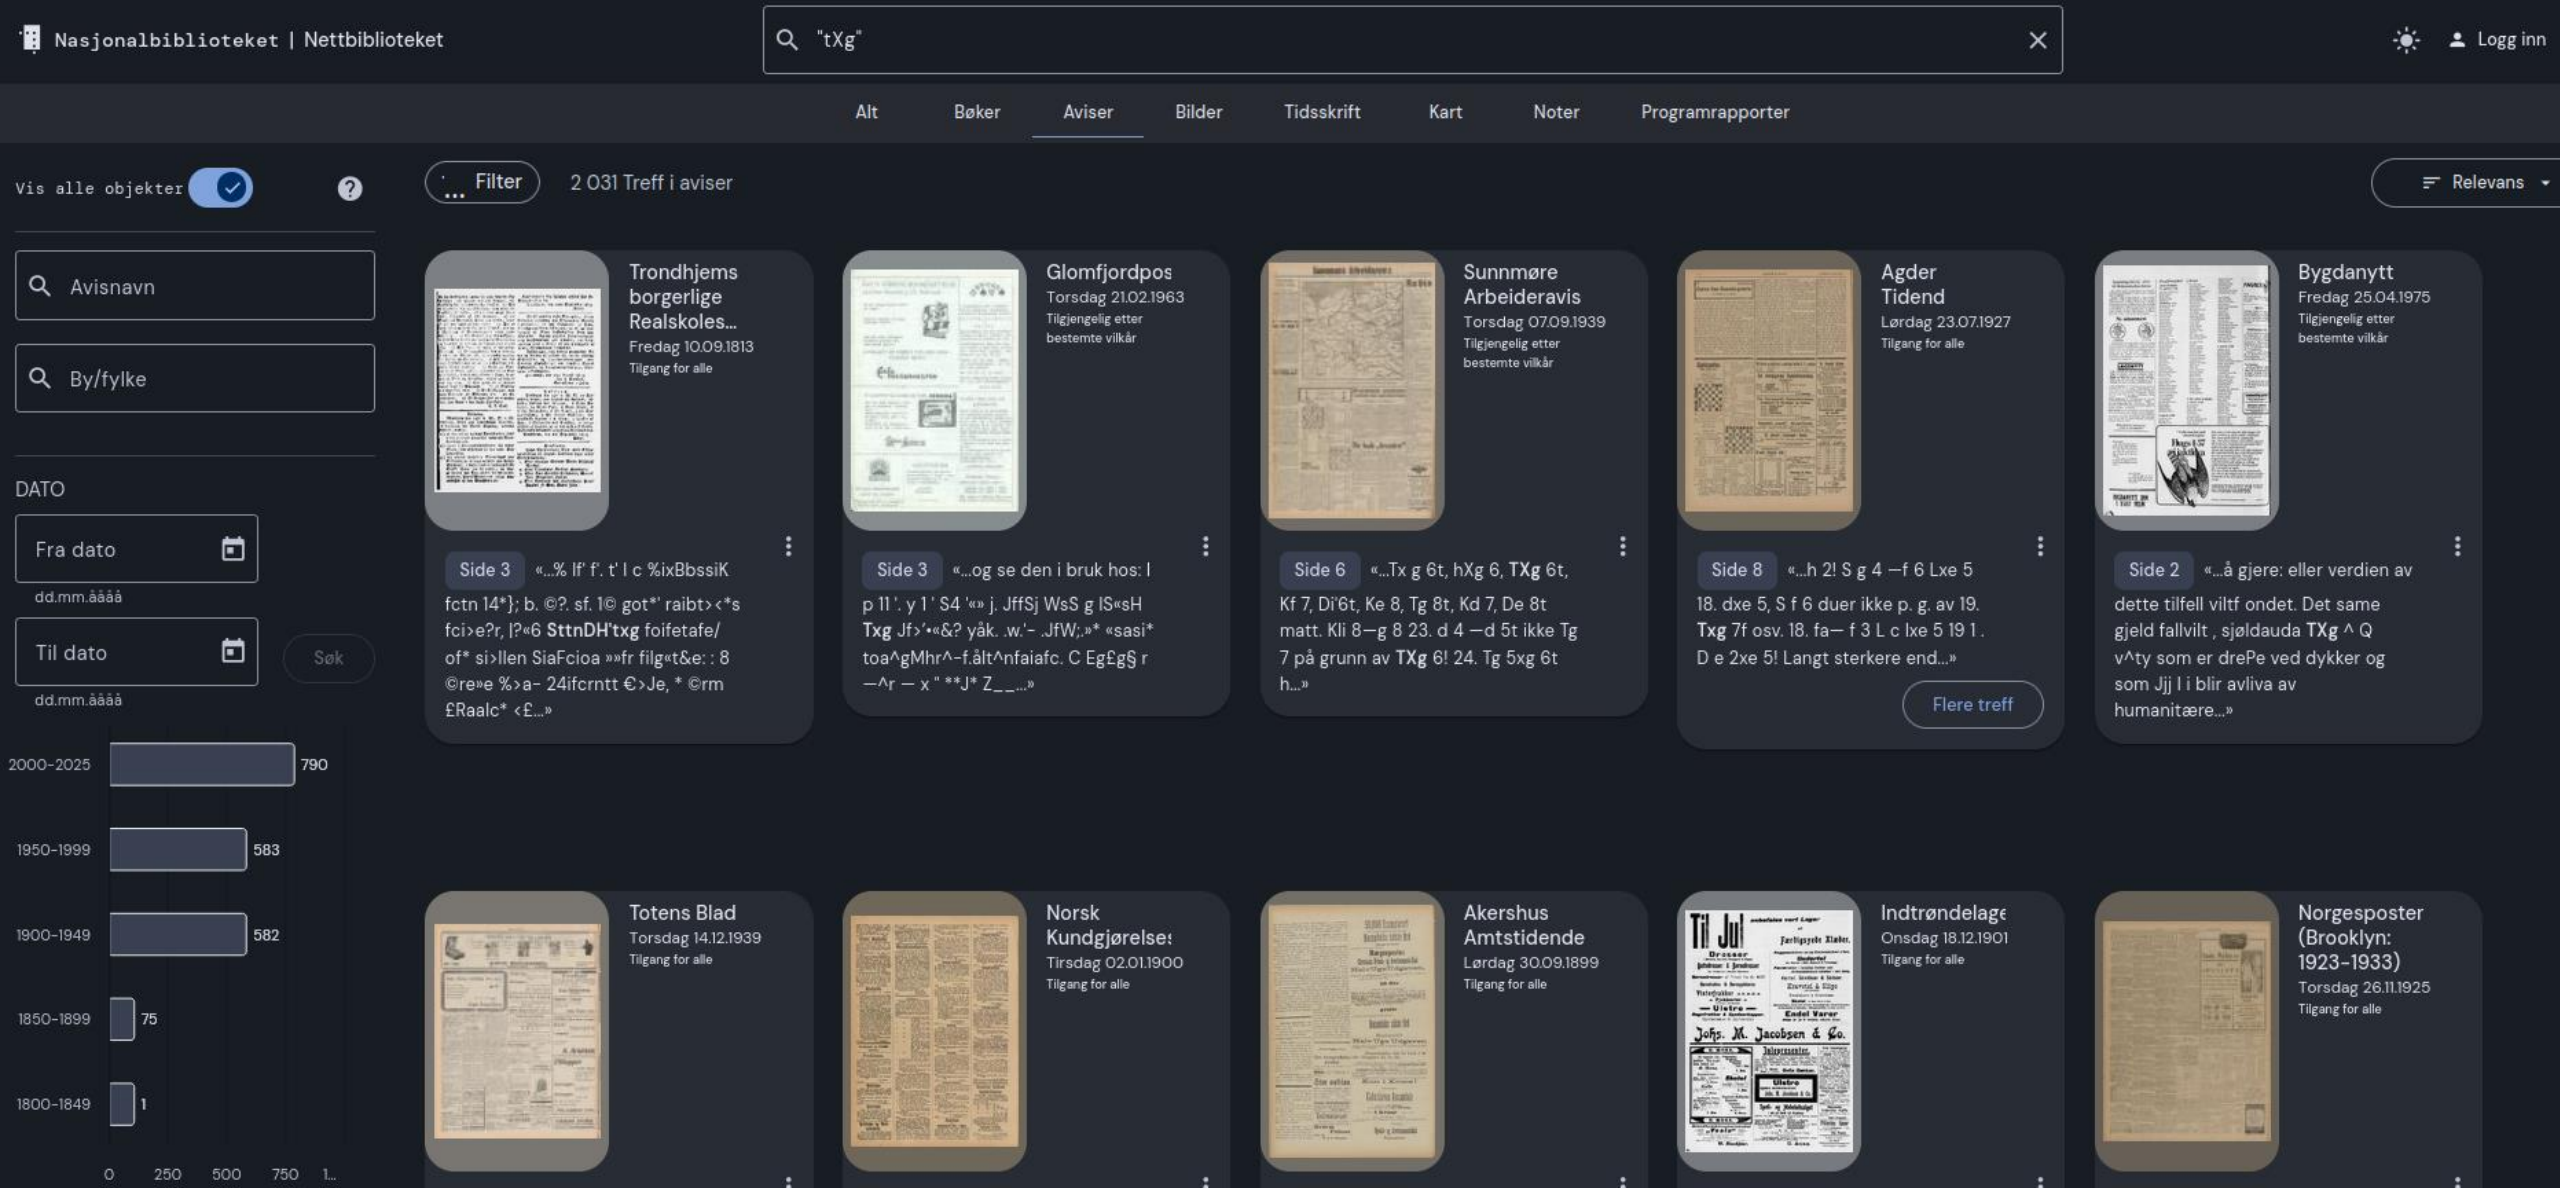
Johnsen, Lars G (2024) “Bibliografiske nettverk: en digital analyse av siteringer” in Sivesind, Kirsten (ed.) *Hvordan studere utdanningspolitikk? Tekster, teorier, tilnærminger*. 157-184.

Johnsen, Lars (2023) “Å bruke språkteknologi til å undersøke medisinske ord”, *Michael*, 20(Supplement 31), 133-42. Tilgjengelig fra: https://www.michaeljournal.no/article/2023/02/Å bruke språkteknologi til å undersøke medisinske ord (Hentet: 2023)

Hanssen, Jens-Morten (2023) “Jon Fosse på den globale scenen: En dataanalyse”, *Teatervitenskapelige studier*,

Digitaliseringsløypa bruker modeller for tekstekstraksjon





dette skaper nye artefakter i de digitaliserte objektene

Tekstekstraksjon er nødvendig for søk i nettbiblioteket, men har også ført til at vi har store mengder av digital tekst

– Jorden er på en måte dyrenes verden, så vi må ta godt vare på den, oppsummerer hun.

Det ser i hvert fall ut som om Annelene Sett Gjessing allerede har oppnådd noe av visjonen sin med teaterstykket, nemlig å få frem et større engasjement rundt miljø blant de unge.

«Den hemmelige steinen» spilles i Asker Kulturhus den 23., 25. og 26. mars.

66 77 00 00

helge.heyerdahl@budstikka.no

vekk».

TITA ENSTAD (12): - Min rolle er at jeg skal spille en bokhylle. Jeg skal kle meg i svart kostyme og stå helt stille.



for vanligvis øver vi hver for oss i grupper, så dette blir spennende, sier Aase.

– Jorden er på en måte dyrenes verden, så vi må ta godt vare på den, oppsummerer hun.

Det ser i hvert fall ut som om Annelene Sett Gjessing allerede har oppnådd noe av visjonen sin med teaterstykket, nemlig å få frem et større engasjement rundt miljø blant de unge.

TITA ENSTAD ?12?: - Min

rolle er at jeg skal spille en bokhylle. Jeg skal kle meg i svart kostyme og stå helt stille. helge.heyerdahl@budstikka.no

«Den hemmelige steinen» spilles i Asker Kulturhus den 23., 25. og 26. mars.

Martine var ikke så sikker på hvilken rolle

66 77 00 00

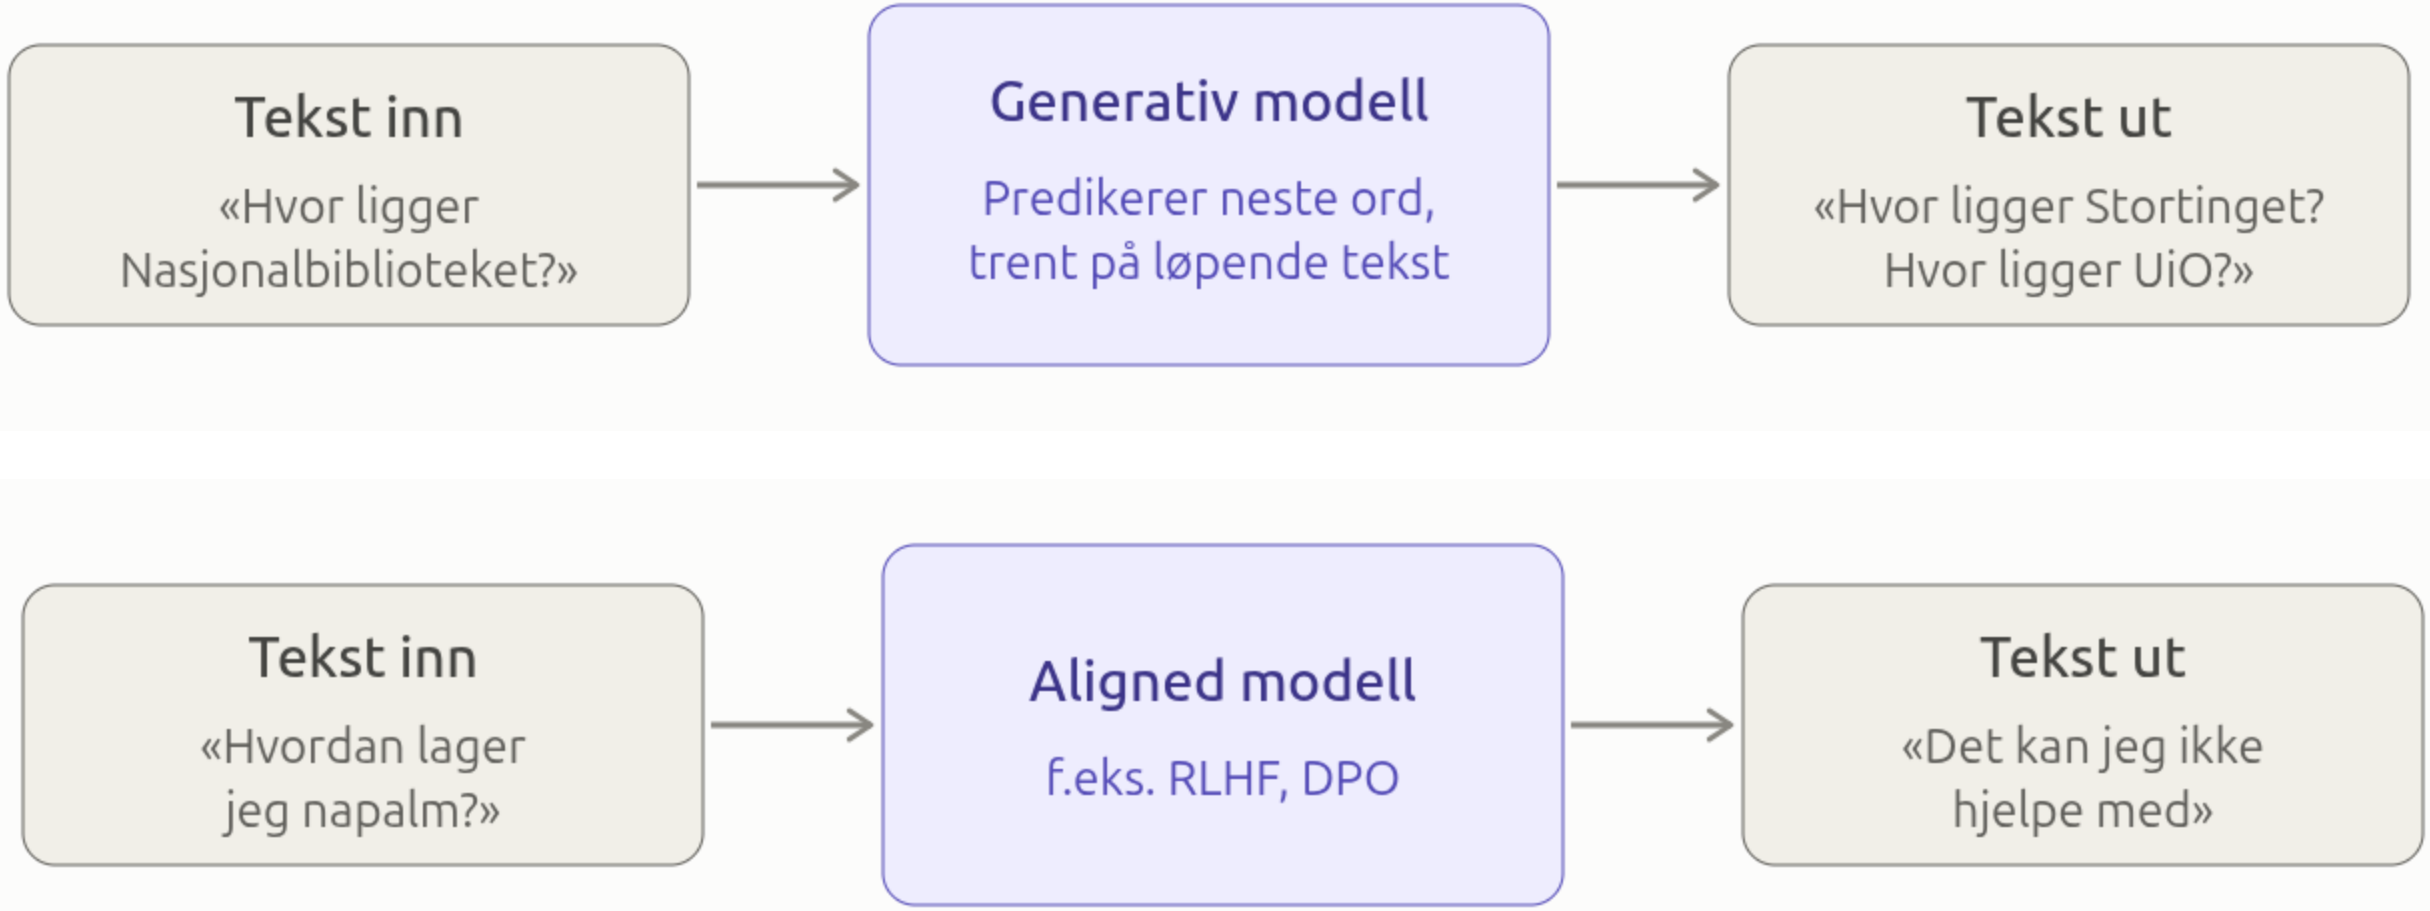
NBs AI-lab har laget språkmodeller i flere år, og i 2025 ga regjeringa NB i oppdrag å lage språkmodeller for hele Norge





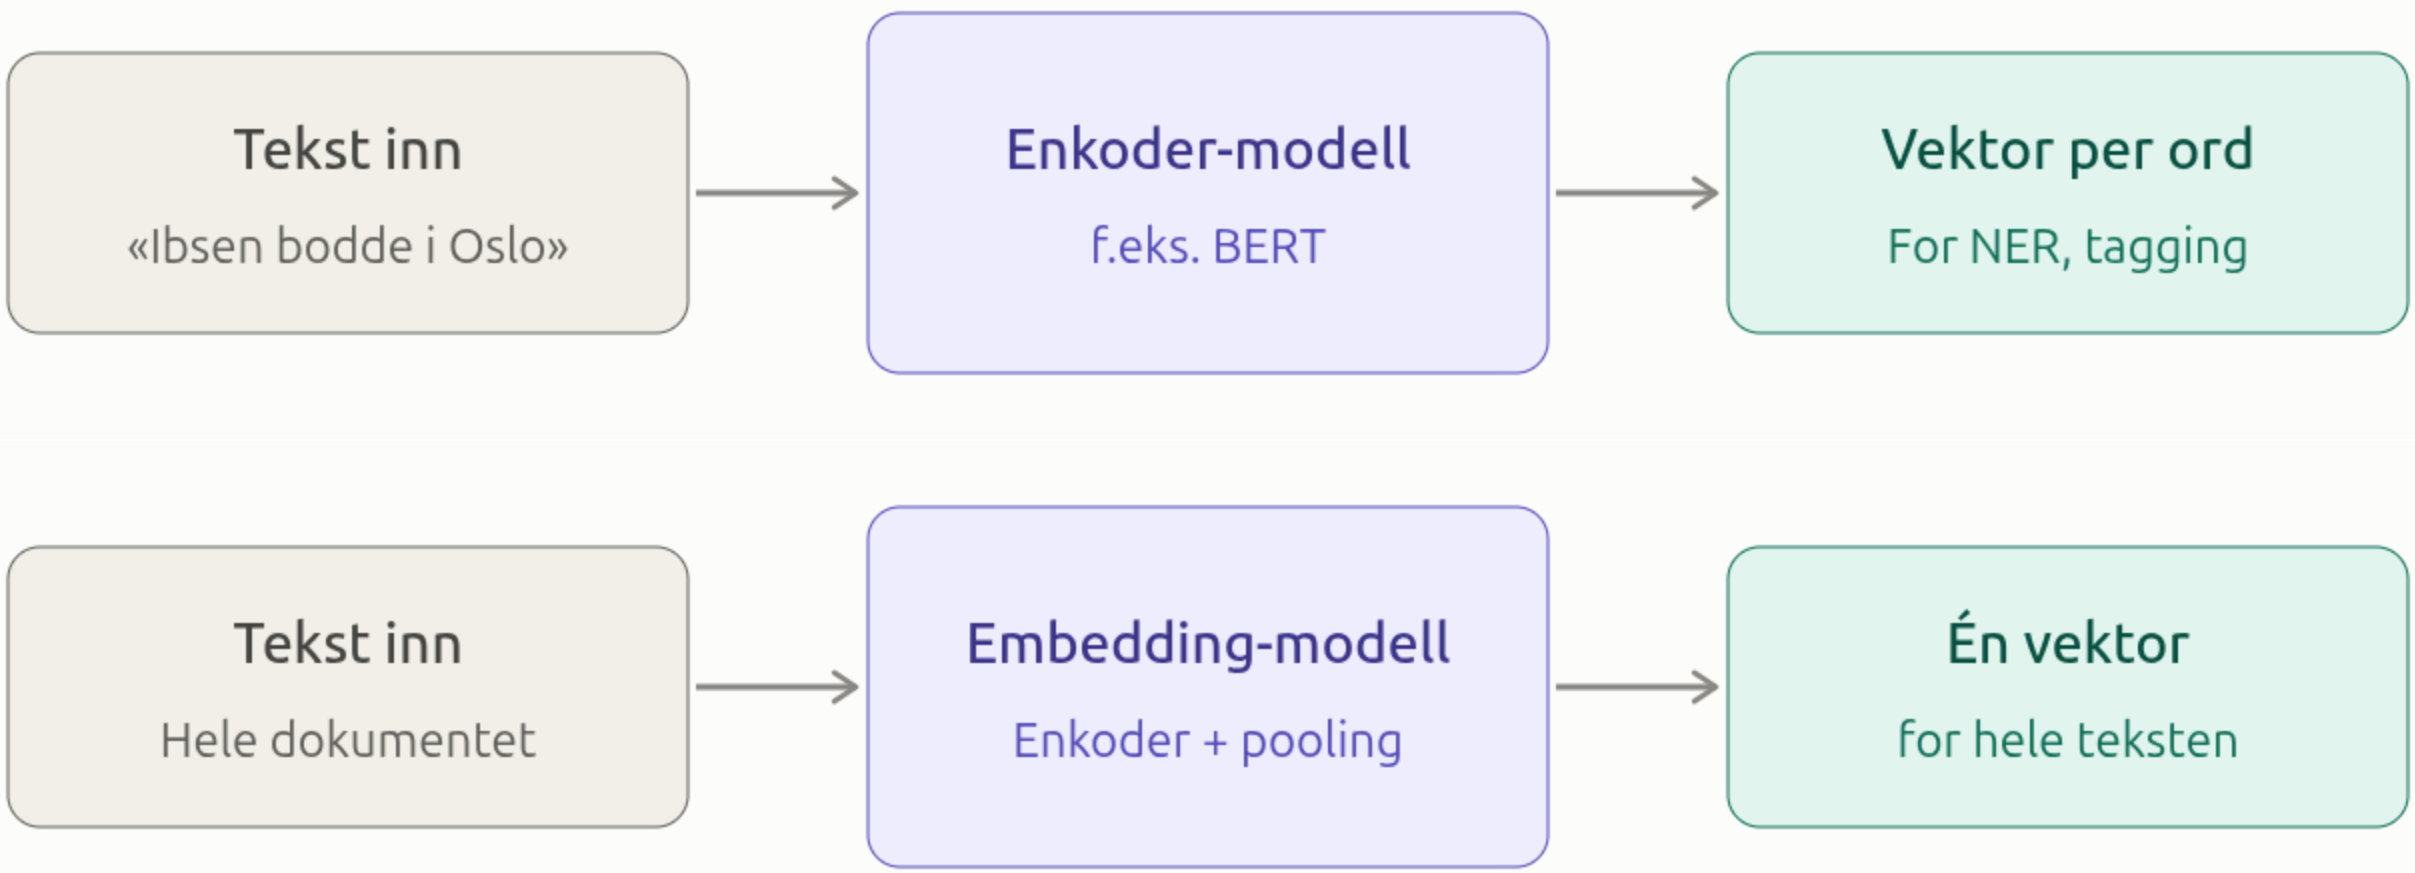
Ikke alle språkmodeller er GPT-modeller!

GPT-modeller genererer tekst

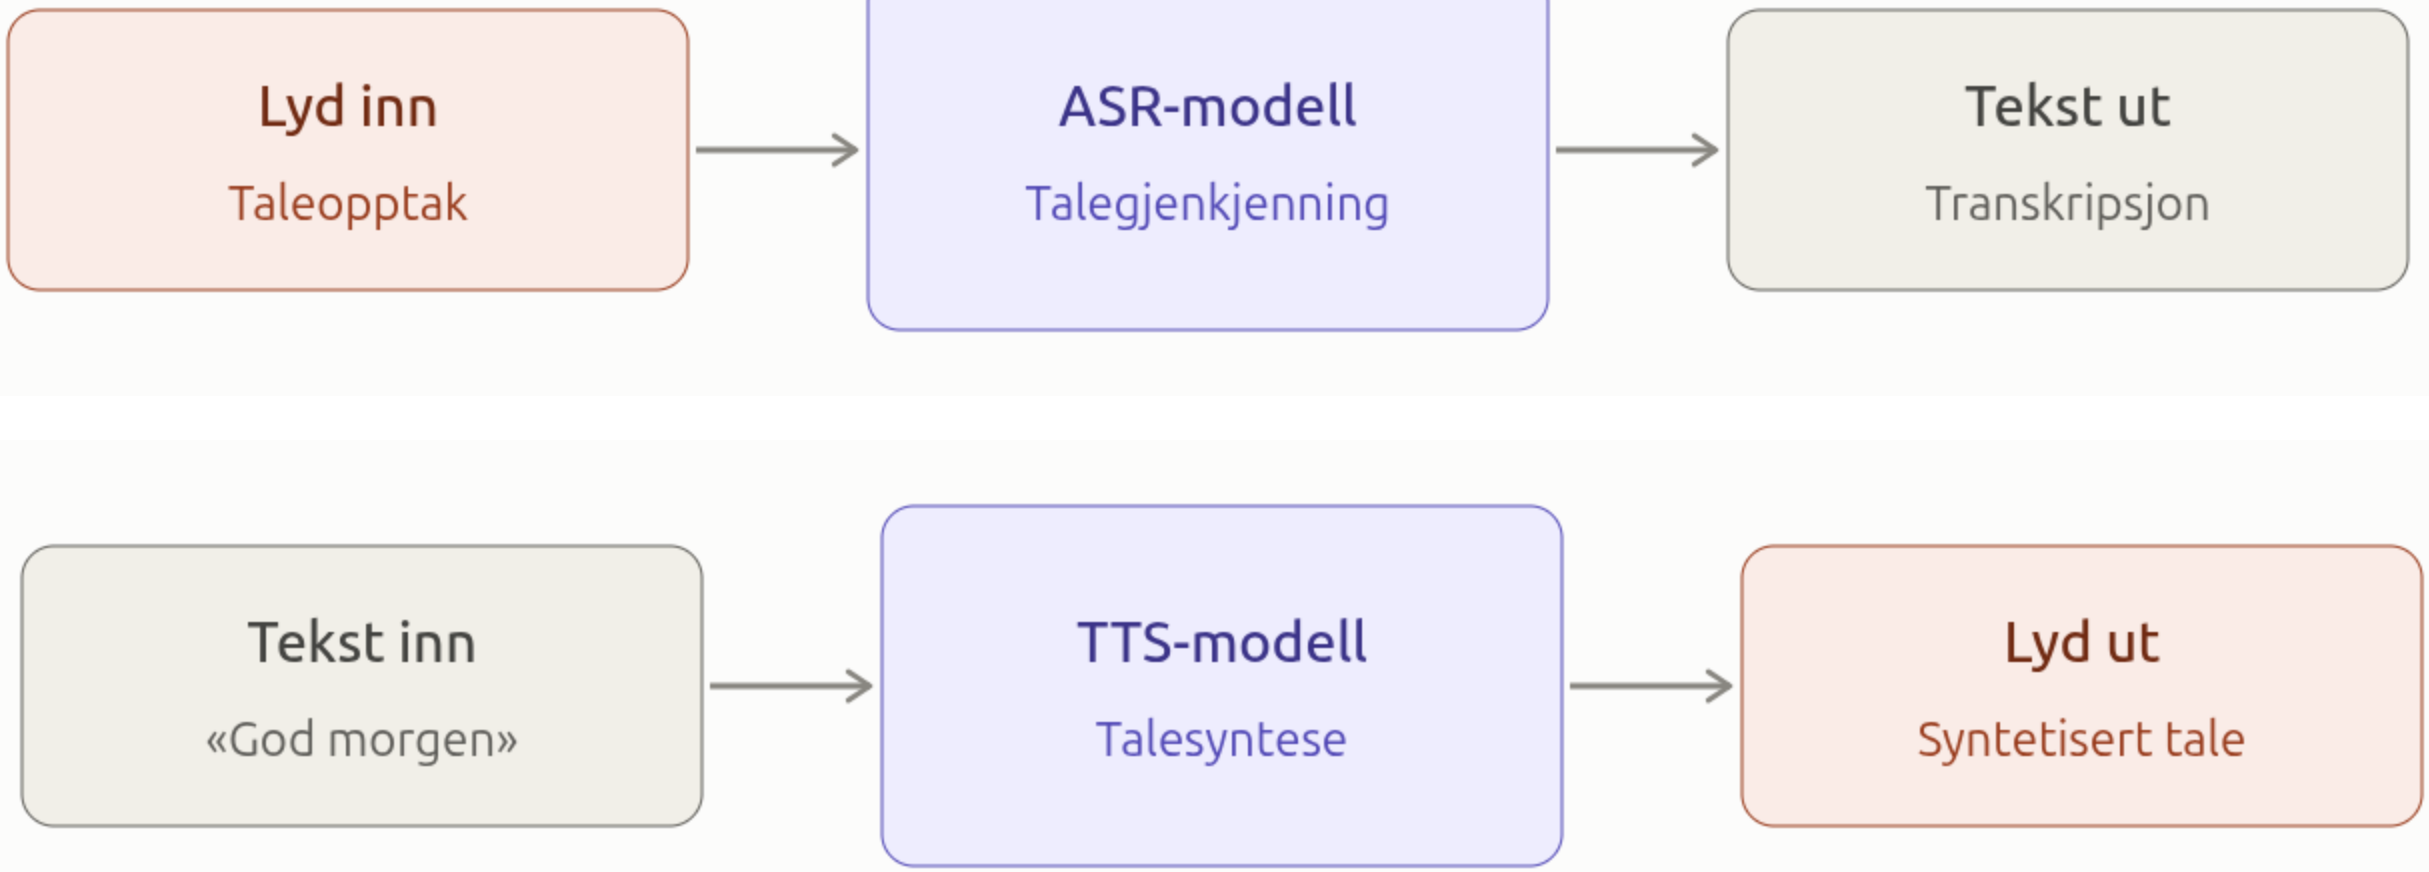


Enkoder-modeller gir ut vektorrepresentasjoner

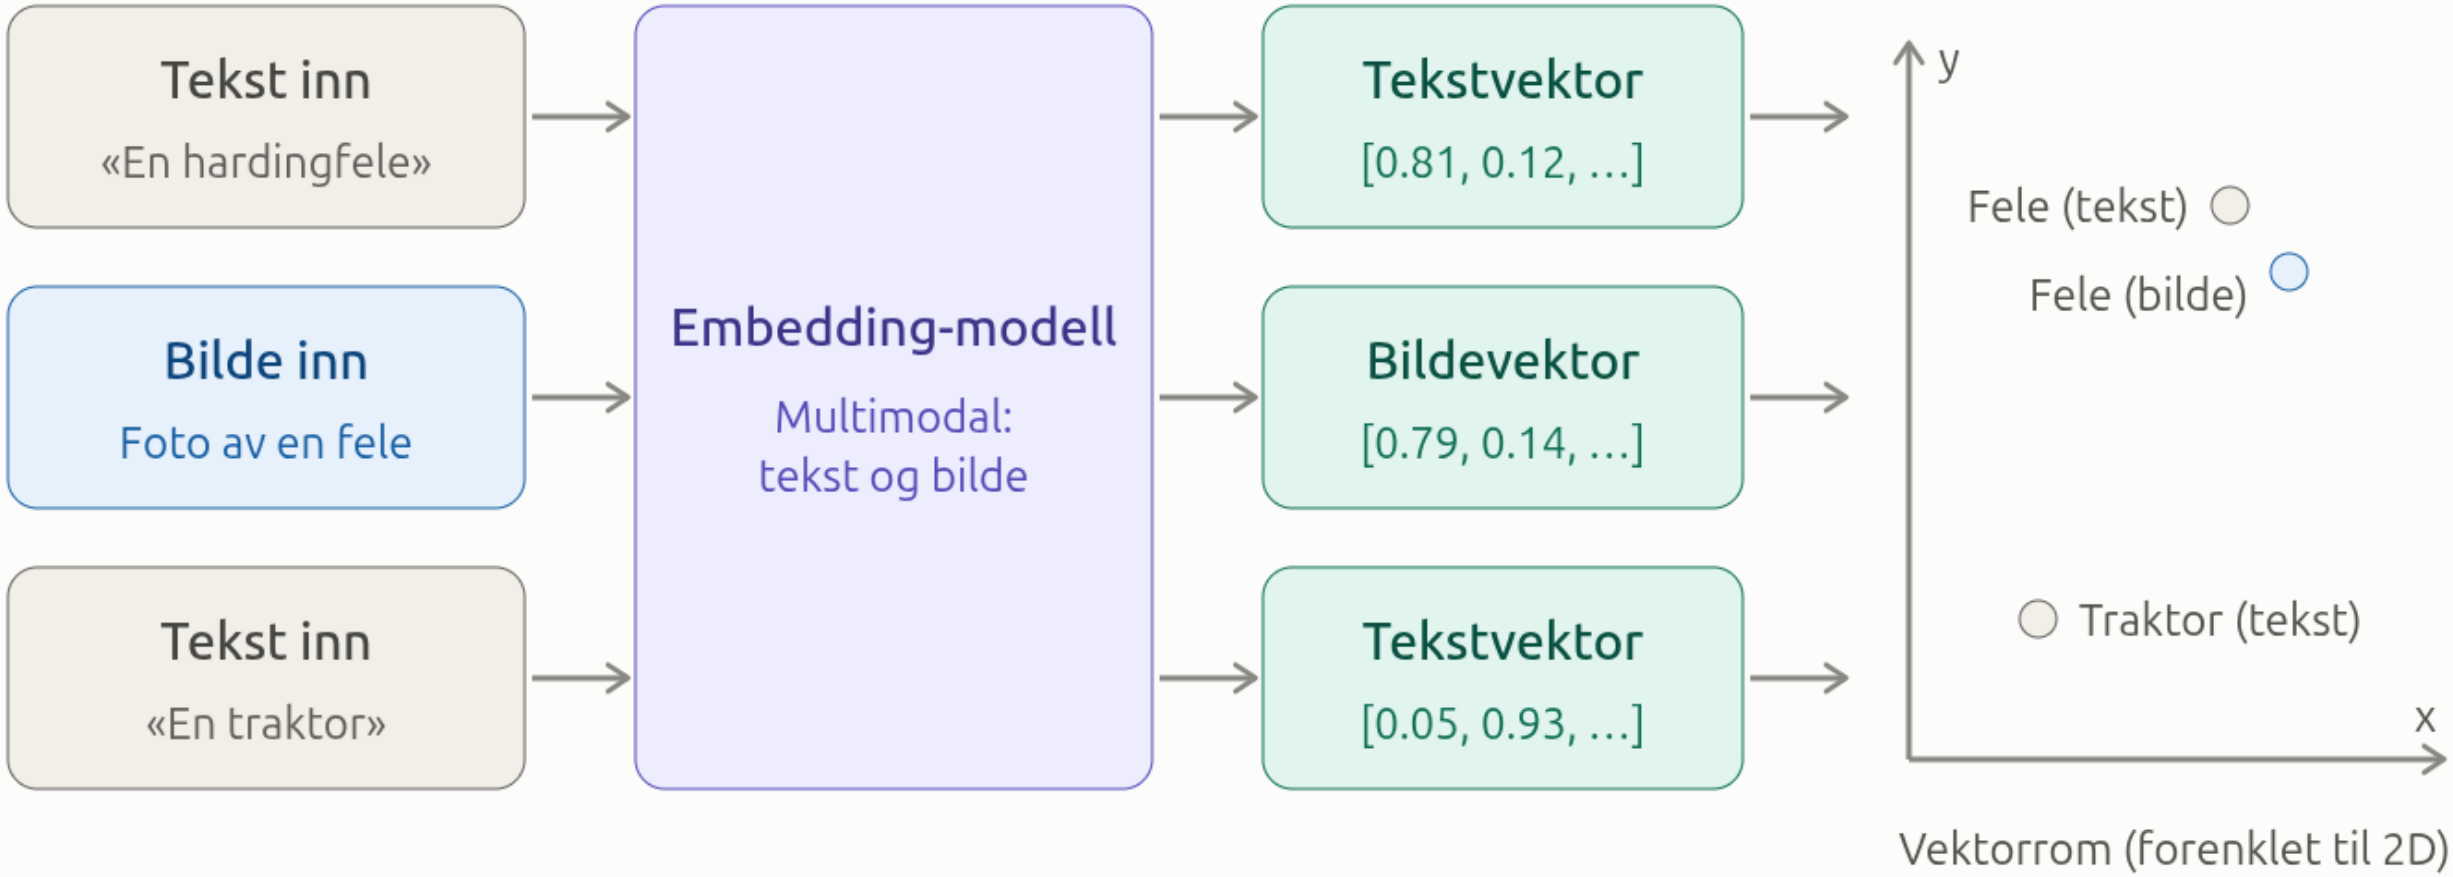
vektorene enkoder tekstens *betydning*



Språkdata er ikke bare tekst



Noen modeller støtter flere modaliteter





Nasjonalbiblioteket AI Lab Team Non-Profit Verified

https://ai.nb.no/ NbAiLab

Activity Feed Follow 508

Modellene våre kan lastes ned fra huggingface: huggingface.co/NbAiLab

NbAiLab 's collections 21

NB-ASR UNN

Internal synthetic NorMed mixture test models from the NB-ASR project. Acce…

- NbAiLab/nb-asr-unn-nb-control-10k
  Automatic Speech Recognition • 0.8B • Updated Sep 24 • 2
- NbAiLab/nb-asr-unn-normed10-10k
  Automatic Speech Recognition • 0.8B • Updated Sep 24 • 8
- NbAiLab/nb-asr-unn-normed50-10k
  Automatic Speech Recognition • 0.8B • Updated Sep 24 • 7
- NbAiLab/nb-asr-unn-normed100-10k

Borealis 2 Preview

Preview release of the Borealis 2 family of models by the National Library of N…

- NbAiLab/borealis2-31b-preview
  Image-Text-to-Text • 31B • Updated 28 days ago • 417
- NbAiLab/borealis2-26b-a4b-preview
  Image-Text-to-Text • 26B • Updated Sep 4 • 224 • 4
- NbAiLab/borealis2-26b-a4b-preview-gguf
  Image-Text-to-Text • 25B • Updated Sep 23 • 1.6k
- NbAiLab/borealis2-e4b-preview

NB-TTS

NbAiLab Norwegian Voices 1

Opplest · VoxCPM2 8
Generate Norwegian speech from your text

Borealis Embed

Borealis Embed is a family of embedding models pretrained from scratch on …

- NbAiLab/borealis-embed-212m
  Sentence Similarity • 0.2B • Updated Sep 4 • 1.28k • 7

NB-sami

- NbAiLab/nb-sami-asr-nemotron-3.5-streaming
  Automatic Speech Recognition • Updated Jun 5 • 34 • 1
- NbAiLab/salmon-f5-tts-north-sami
  Updated Dec 5, 2024 • 40

North Sami Realtime ASR
Realtime North Sami ASR with Nemotron 3.5.

Borealis

Borealis is a new family of Norwegian-centric instruction-tuned language mo…

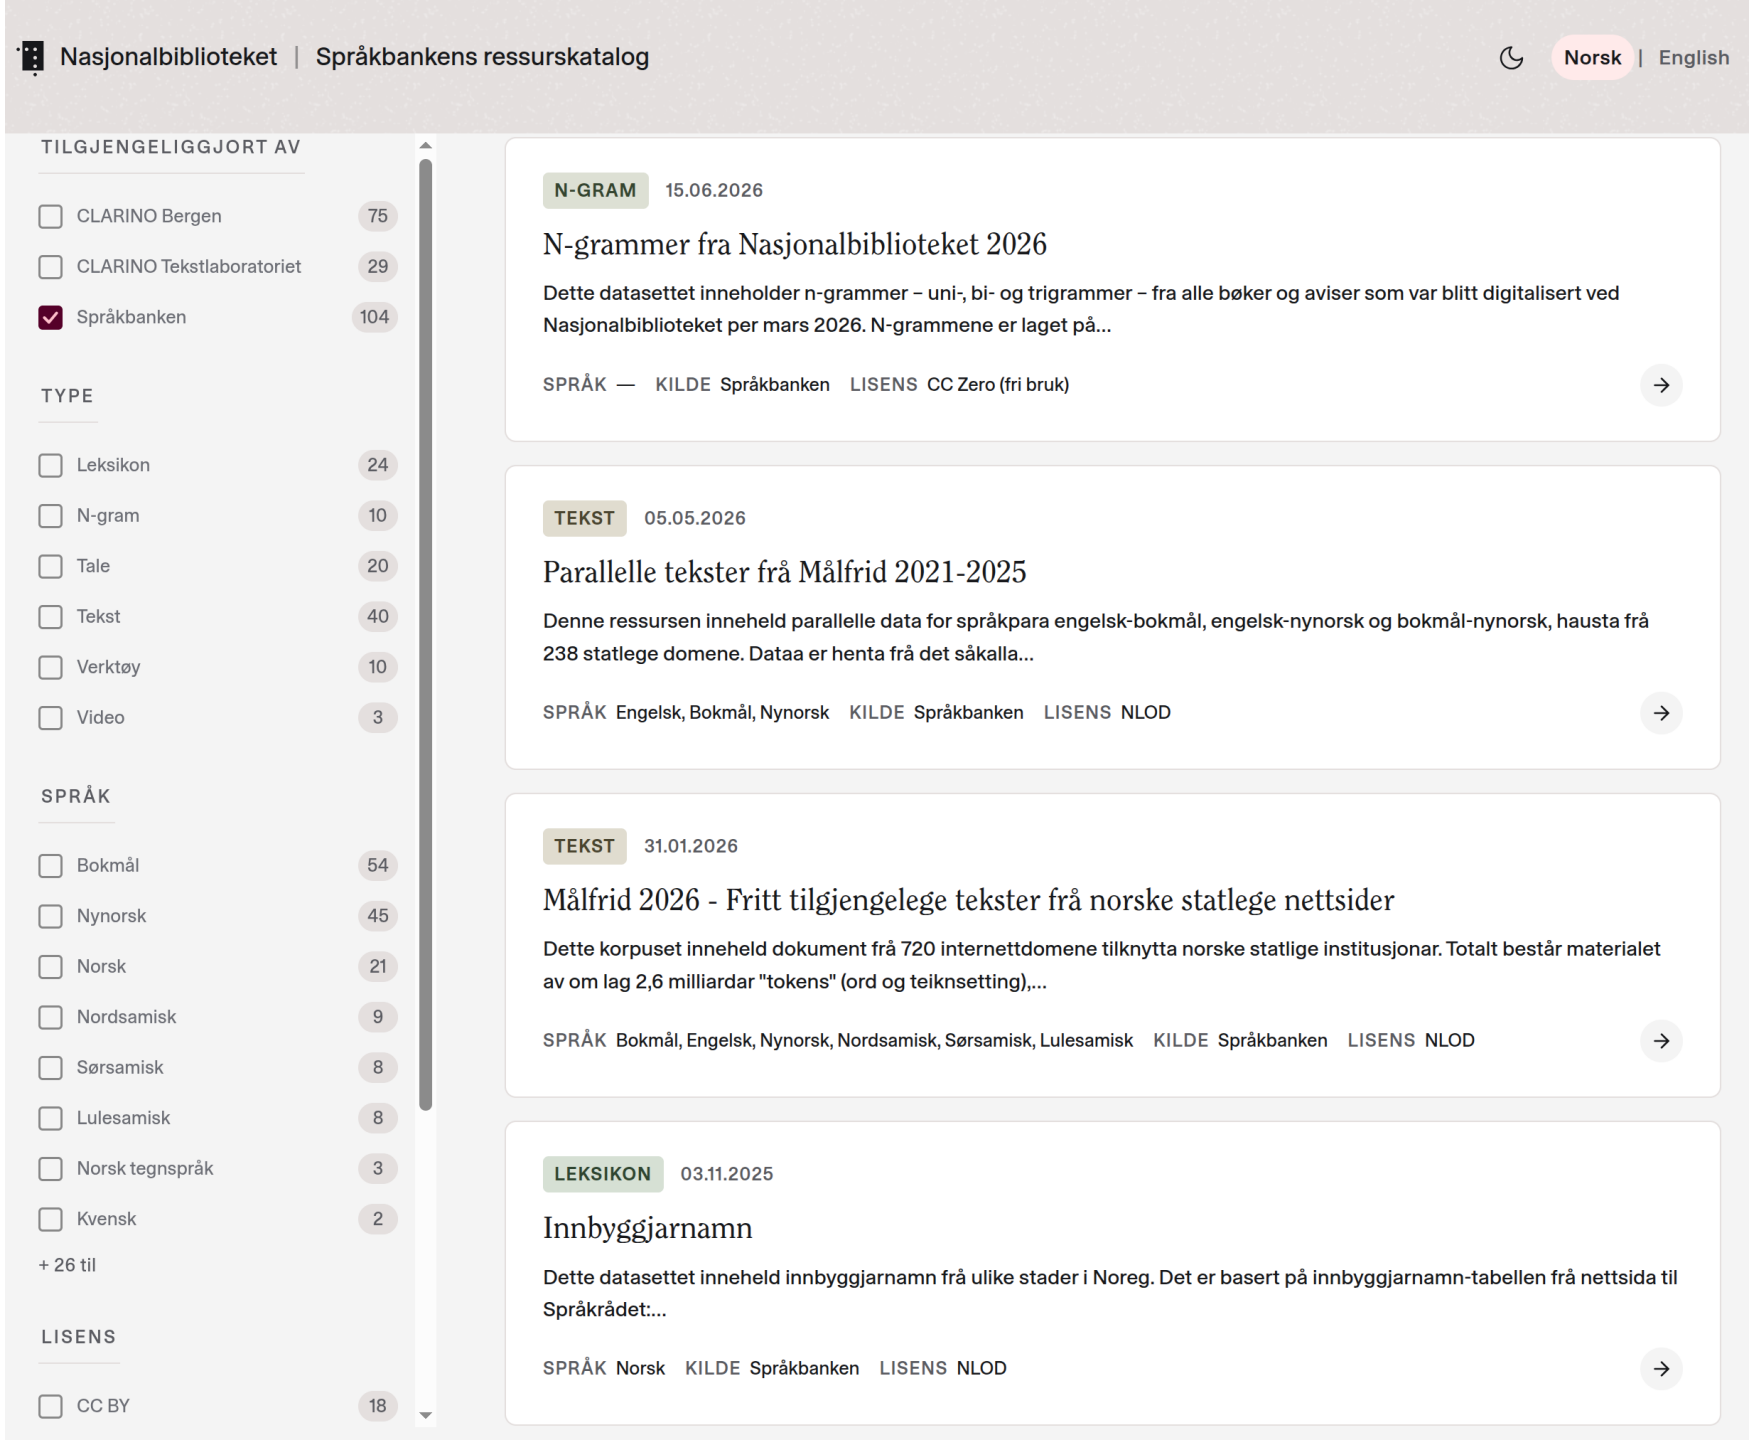
- NbAiLab/borealis-27b
  Image-Text-to-Text • 27B • Updated 11 days ago • 3.3k • 10
- NbAiLab/borealis-12b
  Image-Text-to-Text • 12B • Updated 11 days ago • 78
- NbAiLab/borealis-4b
  Image-Text-to-Text • 4B • Updated 11 days ago • 82 • 3
- NbAiLab/borealis-1b

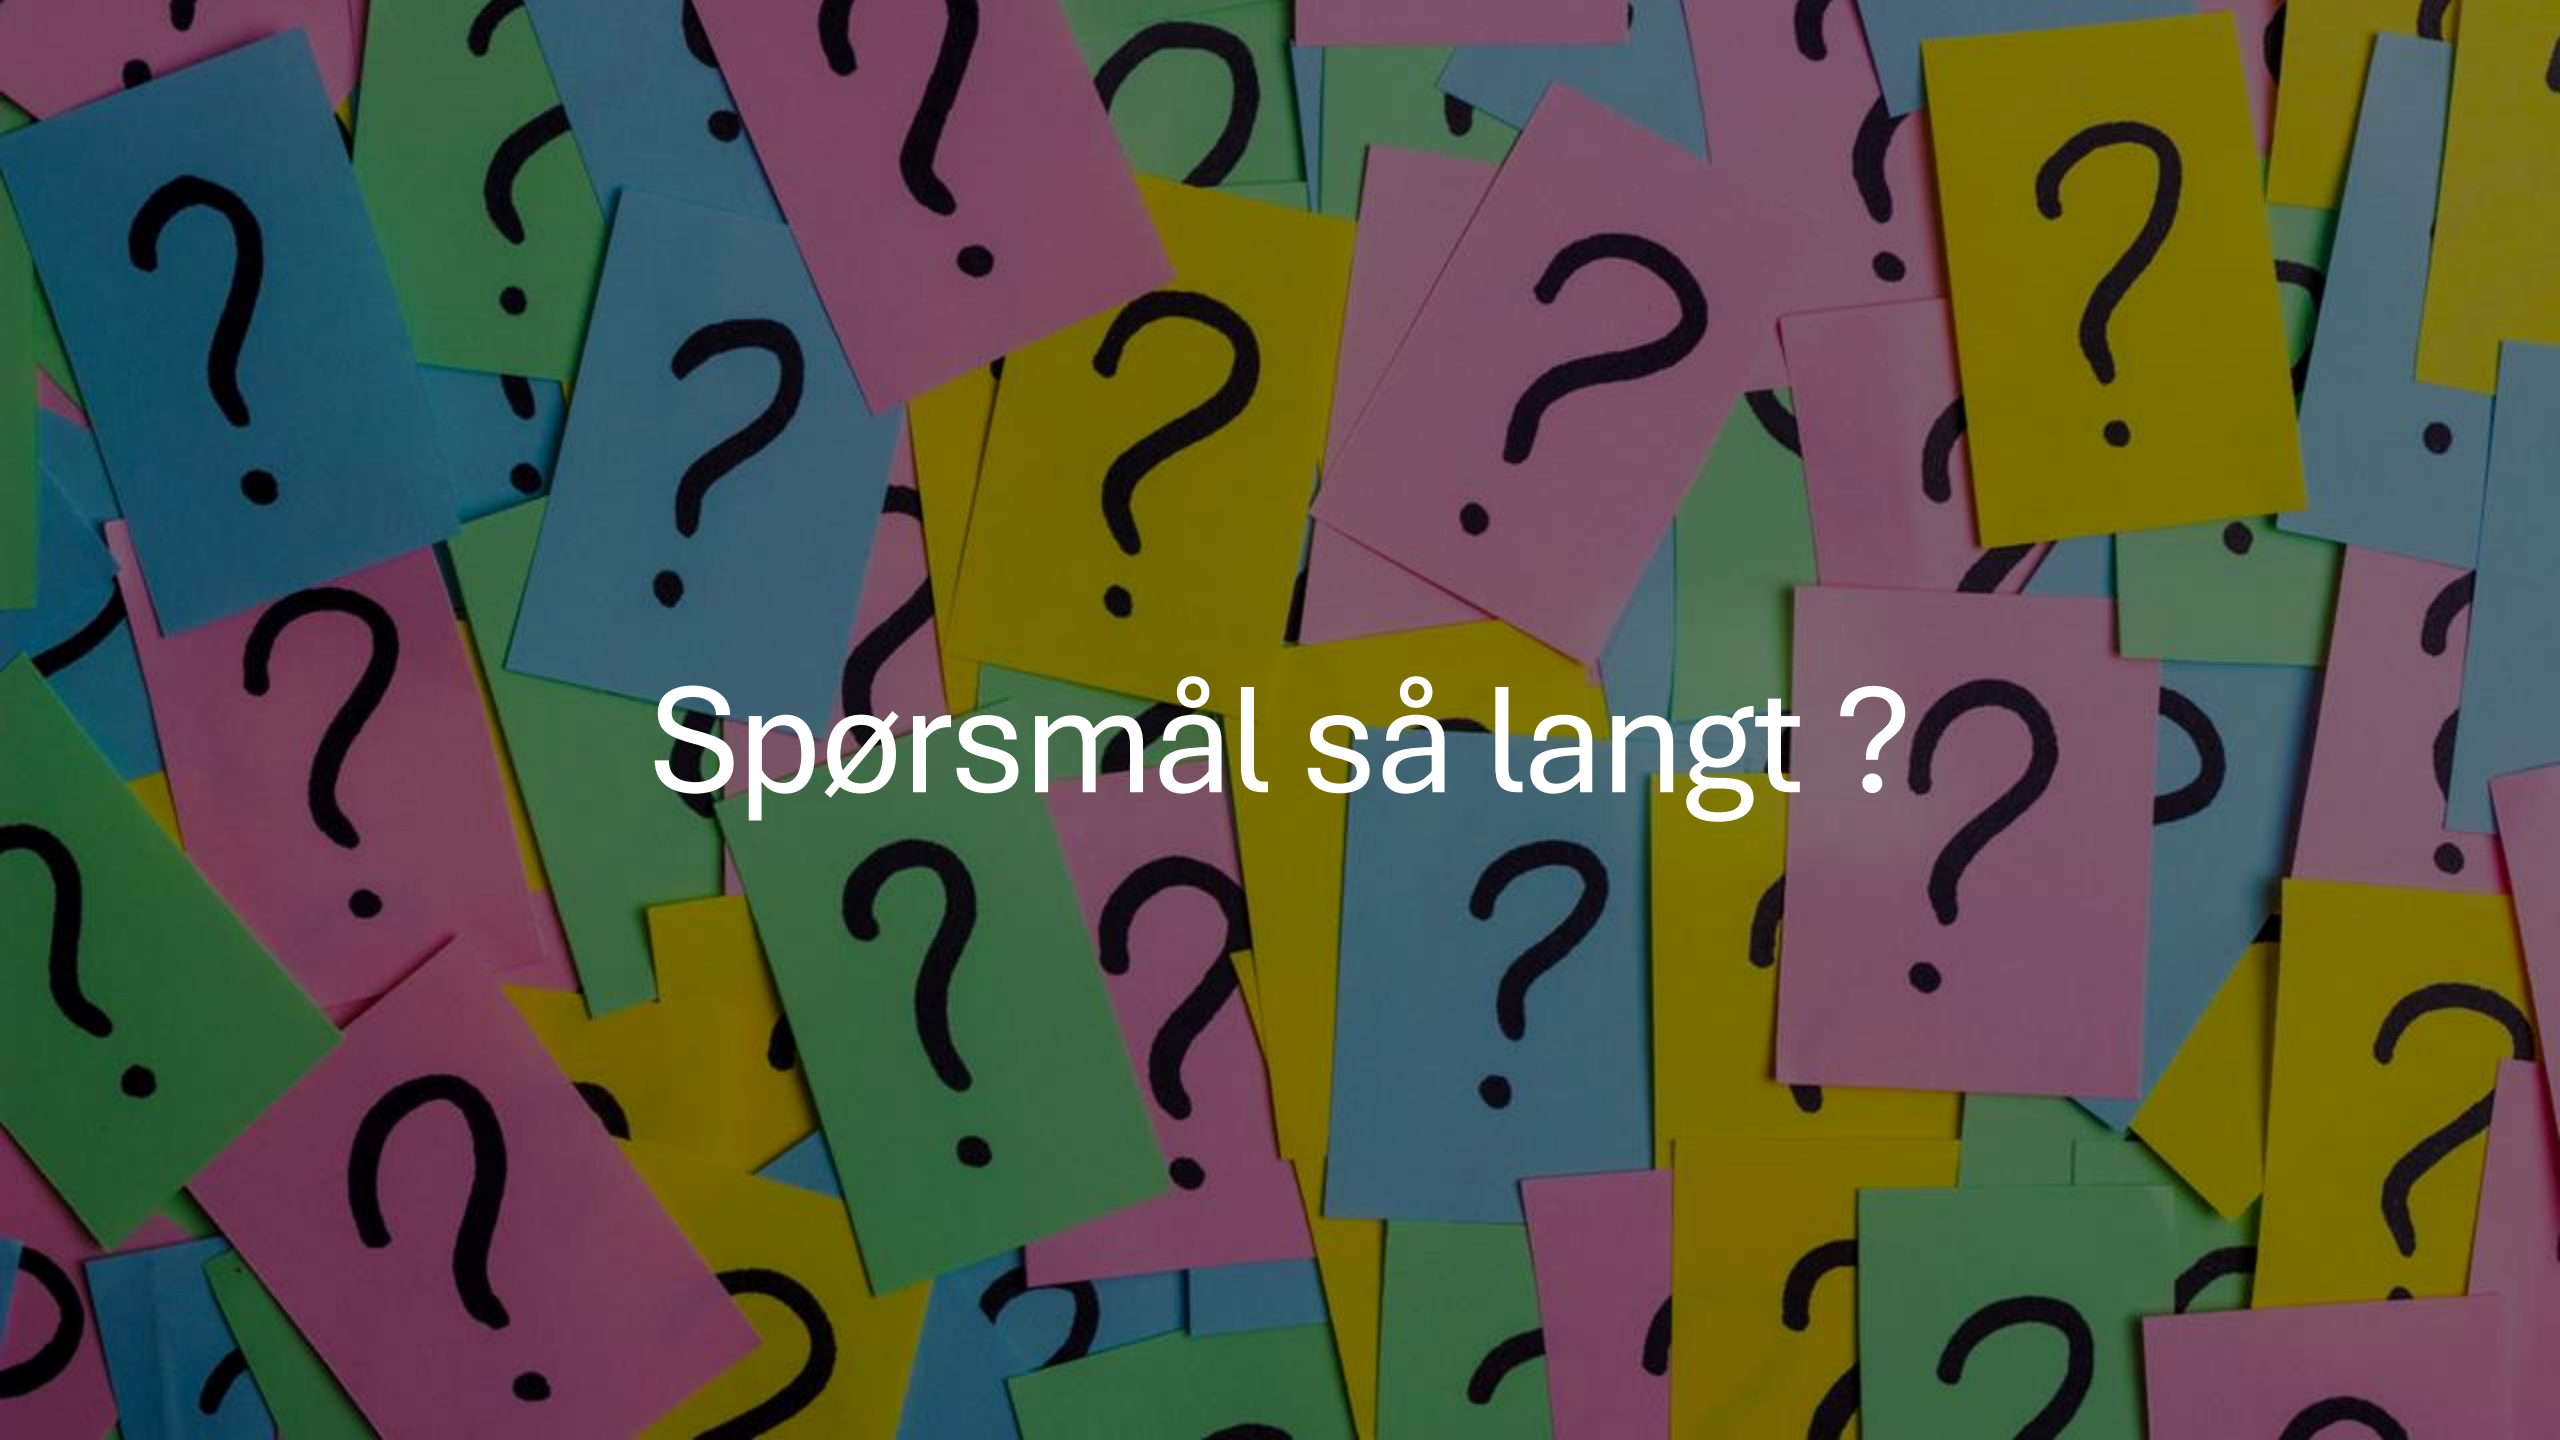
NB-ASR-BETA

Beta testing resources in the NB-ASR project

Språkbankens ressurskatalog inneholder åpne datasett for språkteknologi

nb.no/sprakbanken/ressurskatalog/




Spørsmål så langt ?

Dokumentvektorer og temamodellering

https://github.com/NationalLibraryOfNorway/dhlab-text-analysis

